编号：

四川农业大学

本科毕业论文（设计）

（2025 届）

题目：深度学习支持下川西传统建筑木构件多损伤智能识别与健康监测研究

学院：建筑与城乡规划学院

专业：城乡规划

学生姓名：唐胜圳　　学号：202008077

导师：肖海　　职称：讲师

完成日期：2025 年 4 月 29 日

论文原创性声明

本人郑重声明：所呈交的学位论文是我个人在导师指导下进行研究工作所取得的成果。尽我所知，除了文中特别加以标注和致谢的地方外，学位论文中不包含其他个人或集体已经发表或撰写过的研究成果，也不包含为获得四川农业大学或其它教育机构的学位或证书所使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

本科生签名：唐雅竹　　2025年 5 月 4 日

论文版权使用授权书

本人完全了解四川农业大学有关保留、使用学位论文的规定，即：学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。同意四川农业大学可以用不同方式在不同媒体上发表、传播学位论文的全部或部分内容。

□ 本论文延迟____年后公开，到期后适用本授权。

（限制级及涉密学位论文请在□内划“√”，并填写延迟公开时限。不勾选此项，默认为公开）

本科生签名：唐雅竹　　2025年 5 月 4 日

导师签名：　　2025年 5 月 4 日

目录

摘要.....1

关键词.....1

Abstract.....2

Keywords.....2

1.绪论.....2

1.1 研究背景及意义.....3

1.2 国内外研究现状.....4

1.3 本文主要研究内容及贡献.....5

2.研究区域概况.....6

2.1 实验区概述.....6

2.2 现状损伤调查.....7

3.数据集.....8

3.1 数据采集.....8

3.2 数据集制作.....10

3.3 数据集特征分析.....11

4.损伤检测系统开发.....12

4.1 计算机视觉目标检测算法.....12

4.2 注意力机制.....14

4.2.1 Vision Transformer (ViT)的引进.....15

4.2.2 Squeeze-and-Excitation (SE) 的应用.....15

4.2.3 注意力机制的协同作用.....16

4.3 混合聚类非极大值抑制(MC-NMS).....16

4.4 Exif 文件地理信息解码方案.....17

4.5 基于 Pyside2 的损伤检测系统开发.....18

5.结果与讨论.....21

5.1 改进模型的训练与性能验证.....22

5.2 改进模型与原始模型性能对比.....26

5.3 注意力机制关注区域对比.....29

5.4 传统建筑木构件损伤检测系统实践 30
6.结论 32
参考文献 32
数据可用性声名 36
致谢 36

深度学习支持下川西传统建筑木构件多损伤智能识别与健康监测研究

城乡规划专业 唐胜圳

导师：肖海

摘要：本文针对中国西南地区传统建筑木构件损伤检测依赖人工效率低、现有木材损伤数据集因背景复杂度低（单一实验室环境）与真实古建筑场景（复杂纹理、多变光照及老化木质基底）存在显著表征差异的问题，构建了首个面向传统建筑木构件损伤的专用数据集（1246 张原始图像，增强至 2783 张）。数据集涵盖节子、裂缝、虫蛀、腐朽四类损伤。在 YOLO v8m 网络特征提取阶段引入 ViT 模块，在三个检测头前插入 SE 模块，缓解模型在面对检测任务中损伤表征差异大，小目标较多表现出的难收敛、低精度问题（mAP50 提升 4%,mAP50-95 提升 3%）。混合聚类的 NMS 算法(MC-NMS)将碎片化指数较传统 NMS 降低 23.6%。研发的检测系统集成地理信息，实现 EXIF 数据自动解析与 GIS 地图映射，在雅安望鱼古镇传统建筑群检测任务中识别精度达 0.83，损伤检测阶段效率较人工提升 43 倍。本研究为文化遗产保护提供了高效低成本的技术路径。

关键词：传统建筑木构件；损伤检测；YOLO v8；深度学习；地理信息系统

Research on Intelligent Identification and Health Monitoring of Multi-Damage in Traditional Wooden Components of Sichuan West Architecture Supported by Deep Learning

Tang Shengzhen

Xiao hai

Abstract: This study addresses the significant issue of low efficiency in manual inspection for damage detection in traditional wooden structures in Southwest China, as well as the marked differences in representation between existing wood datasets from controlled laboratory environments and real historical building scenarios, which feature complex textures, variable lighting, and aged wooden substrates. We constructed the first dedicated damage dataset for ancient buildings, which consists of 1,246 original images, augmented to 2,783 images, covering four types of damage: knots, cracks, woodworm, and decay. The study proposes a dual-stage optimization based on YOLOv8, introducing a ViT module in the feature extraction stage of the network and adding SE modules before the three detection heads to alleviate issues related to substantial disparities in damage representation and the prevalence of small targets (with mAP50 increased by 4% and mAP50-95 increased by 3%). Additionally, a mixed clustering NMS algorithm (MC-NMS) is designed, resulting in a 23.6% reduction in fragmentation index compared to traditional NMS. The developed detection system integrated geographic information, automating EXIF data parsing and GIS mapping. In the detection task of the traditional architectural complex in Wangyu Ancient Town, Ya'an, the recognition accuracy reached 0.59, with detection efficiency improved by 43 times compared to manual methods. This research provides an efficient and cost-effective technological approach for cultural heritage conservation.

Keywords: Traditional Architectural Wood Components; Damage Detection; YOLO v8; Deep Learning; Geographic Information System.

1.绪论

1.1 研究背景及意义

中国传统建筑作为世界三大建筑体系之一，其蕴含着宝贵的文化遗产与历史信息[1]。在中国悠久的历史当中，随着人们不断适应当地的自然环境，留下了许多独特的传统建筑，那些具有一定规模的建筑渐渐集合在一起发展成为一类特定的建筑风格，西南地区传统建筑即作为了其中特征鲜明的一类[2]。木材作为中国西南地区传统建筑的主要构造材料[3]，其健康状态直接影响建筑文化遗产的存续与公共安全。结构设计合理且维护得当的木结构有可能维持几个世纪甚至千年，这凸显出定期修缮维护在建筑文化遗产保护中的关键作用。例如日本法隆寺五重塔，已稳定运行了 1400 多年，超过了设计时的预期寿命[4]。相当多的因素会造成木材的损伤，木构件开裂现象在环境干湿交替或遭受地震、狂风等自然灾害时易发，木构件开裂若超过总长一半或深度达直径四分之一，将削弱其极限承载力以及支撑性能，严重时可能引发整体结构失稳[1]；环境温湿度对木料的劣化进程具有显著的影响，长期高湿度环境易滋生真菌和病虫，导致木材腐烂、病虫害，使木材松散脆弱，危害建筑安全[5]。雅安市是中国西南地区的缩影[6]，降水多，人们将其称为“雨城”。雅安的多雨气候与木材损伤成因存在显著关联，在这样一种气候背景下定期开展传统建筑的修缮维护工作成为了必要。

做好传统建筑木构件的修复加固工作离不开前期的检测，当前，木构建筑损伤检测仍主要依赖人工目视检查，这是一种依赖人类经验与观察能力的检查方法，效率低下且易受主观因素影响[7]，此外，损伤检测的人工成本高昂，给传统木构建筑维护管理部门有限的预算带来压力。虽然目视检查仍然是评估木材状况的基本步骤，但在过去几十年中已经出现了仪器检查方法。Ayodele O. Soge 等人将这些检测方法分为两大类：侵入性和非侵入性方法。侵入性方法包括传统技术（衰减检测钻孔、增量钻孔和钻孔）、射线照相、声学和电阻率技术。非侵入方法包括微波扫描、磁共振成像、X 射线断层扫描和涉及使用木槌的传统技术[8]。每种技术都有特定的适用场景和固有限制，侵入性方法会对建筑产生损害，非侵入性方法的设备成本高，运输不便，并且检测速度慢，不适合广泛传播。然而，最近使用基于图像的方法来检测裂纹的趋势越来越明显。这些方法快速、成本较低且稳健[9]。

1.2 国内外研究现状

近年，AI 技术被广泛的应用于损伤检测领域[10, 11]，方法主要包括图像分类、分割和目标检测三类[12]。图像分类技术通常被用于预测图像中的损伤属于哪一类型[13]。语义分割和实例分割能够通过对图像进行像素级别的分类，输出损伤的类型和近似的形态[14]。目标检测依赖边界框定位损伤在图片中的位置，并提供损伤类型标签[15]。可以说，基于深度学习的建筑损伤检测方法已经颠覆了传统依赖人工识别的工作模式，实现了高效率，高精度的损伤检测[11]。接下来，本文将回顾基于深度学习的建筑损伤检测技术的相关研究进展，讨论现状研究的局限性。

Hallee 等人[16]论证了在砌体裂缝检测中卷积神经网络（CNN）相较于传统计算机视觉技术在域适应、泛化能力等方面的优势。Liu 等人[17]改进 ResNet50 作为了 Deeplab_v3+的骨干网络，提出了一种自动检测建筑裂缝的方法，改进模型精度较原始模型得到了提高。He 等人[18]提出了一种新颖的卷积神经网络 LGFAF-Net 用于检测建筑墙体裂缝，引入了 VMamba 编码器增强模型获取详细信息的能力，提升了模型检测细微裂缝的能力。受到深度学习在道桥裂缝检测领域取得良好效果的启发，Ma 等人[19]对比了 YOLO v3、YOLO v4 和 YOLO v5 在检测古代建筑木结构裂缝任务中的效果，首次将 YOLO 模型应用于古建筑木结构裂缝检测领域。随后目标检测技术被更多的学者用于建筑损伤检测中，Qiu 等人[20]使用 YOLO v8 检测屋顶上可能存在的缺陷，创新点在于提出了一种在大型历史街区或传统村落的背景下快速识别和检测历史建筑遗产疾病的方法。在历史建筑损伤检测领域，Yang 等人[6]进行了类似的研究，验证了 YOLO v8 在自建古建筑屋顶损伤数据集上的效果。Tang 等人[21]提出了一种基于 YOLO v5m 的古建筑墙体损伤识别系统，验证了该模型在排除季节性干扰源和用于实时损伤检测的可能性。Zhu 等人[22]基于整合了 DyHead 和 KernelWarehouse 模块的 YOLO v8，提高了模型在执行古建筑表面损伤检测任务中的 mAP@0.50（IoU 阈值为 0.5 的平均精度）。Chen 等人[23]提出了一种全新的自适应注意力增强 YOLO，融合了 Swin Transformer 的 Cross-Stage Partial Bottleneck，并在预测中使用多头注意力结构对特征进行处理，提高了模型对于裂缝损伤的识别精度。

回顾相关研究进展可发现，深度学习目标检测技术，在传统建筑损伤检测领域呈现出相当可观的应用潜力[19]，就当前情况而言，目标检测算法主要可分为

两阶段和单阶段这两种类型[24]，其中前者以 R-CNN 系列算法[25]为典型代表，检测准确率较高，不过运行速度相对较慢。后者以 YOLO 系列[26]以及 SSD[27]为代表，借助一个模型直接完成定位和类别判断任务，检测效率有了较大提升，只是准确率稍有降低，当然当下已有诸多研究尝试借助改进模型架构[28, 29]以及提高数据多样性[30]来提高损伤检测的精度与效率，然而当前研究仍然存在三方面的局限：目前的研究仅顾及了裂缝这类损伤的检测，对于虫蛀、腐朽等同样对结构安全构成威胁的损伤类型关注不够[31]，致使现有的算法泛化能力受到限制。 传统非极大值抑制算法[32]在不同检测任务中的优化方案较为匮乏，例如在本研究里，传统 NMS 在处理细长裂缝和边缘模糊表征差异较大的腐朽区域时，容易出现重复检测或者漏检[33]， 仅有少数研究考虑到了模型的实际应用部署方案[34]，多数研究仅仅停留在模型开发和性能验证阶段。一般是提出一项改进措施，验证了其效果便完成了研究工作，研究成果未投入实际应用，无法契合实际保护工作中“采集-检测-测量-评估-决策”[35]的全流程需求。

1.3 本文主要研究内容及贡献

本研究提出了一套新颖的方法，有效的解决了上述限制。首先，建立了一个使用低成本设备采集的图像数据集。其次，基于 YOLO v8 提出模型结构优化，缓解了模型在损伤表征差异大、小目标多等情况下性能不佳的问题。第三，设计了一种混合聚类的后处理算法，降低误报率。最后，考虑到实际需要高效检测木构件多类型损伤的使用需求，开发了一款检测系统，该系统可以进行损伤图片的批量检测。进一步完善系统功能，在检测系统的基础上集成了 Exif 文件解析模块，自动提取并转化图像实际拍摄位置的地理信息。在 gis 中完成损伤检测结果与地图的联动，实现损伤定位与数量的可视化，便于进一步的分析与规划工作。

现将本文具体贡献给予总结：其一是发布了一个专门针对传统建筑木构件损伤检测任务的开源图像数据集，此数据集涉及木构件损伤图像以及标签文件，其中损伤被划分成开裂、节子、腐朽、虫蛀这四个类别。其二为改进了一个基于 YOLO v8 的全局特征关注的目标检测模型，提高模型拟合的稳定性和检测精度。其三开发了一种融合聚类算法的非极大值抑制后处理方法，以此降低重复标记损伤，提升检测输出结果的准确性。其四开发 Exif 文件读取解析模块，其能够实现输入一张附属了 Exif 文件的照片，就可以提取其中的经纬度坐标并记录到系统输出文件中。最终为预算有限的传统建筑维护部门设计了一个有低成本、高质

量以及高效率特点的木构件损伤检测系统。

在本文内容安排方面，第 2 节介绍了研究区域概况，第 3 节和第 4 节概述了方法论，包括数据集特征、损伤检测系统、目标检测模型的细节、EXIF 信息解码方案等内容。第 5 节展示了结果及讨论。最后，第 6 节从研究发现中得出结论。

2.研究区域概况

2.1 实验区概述

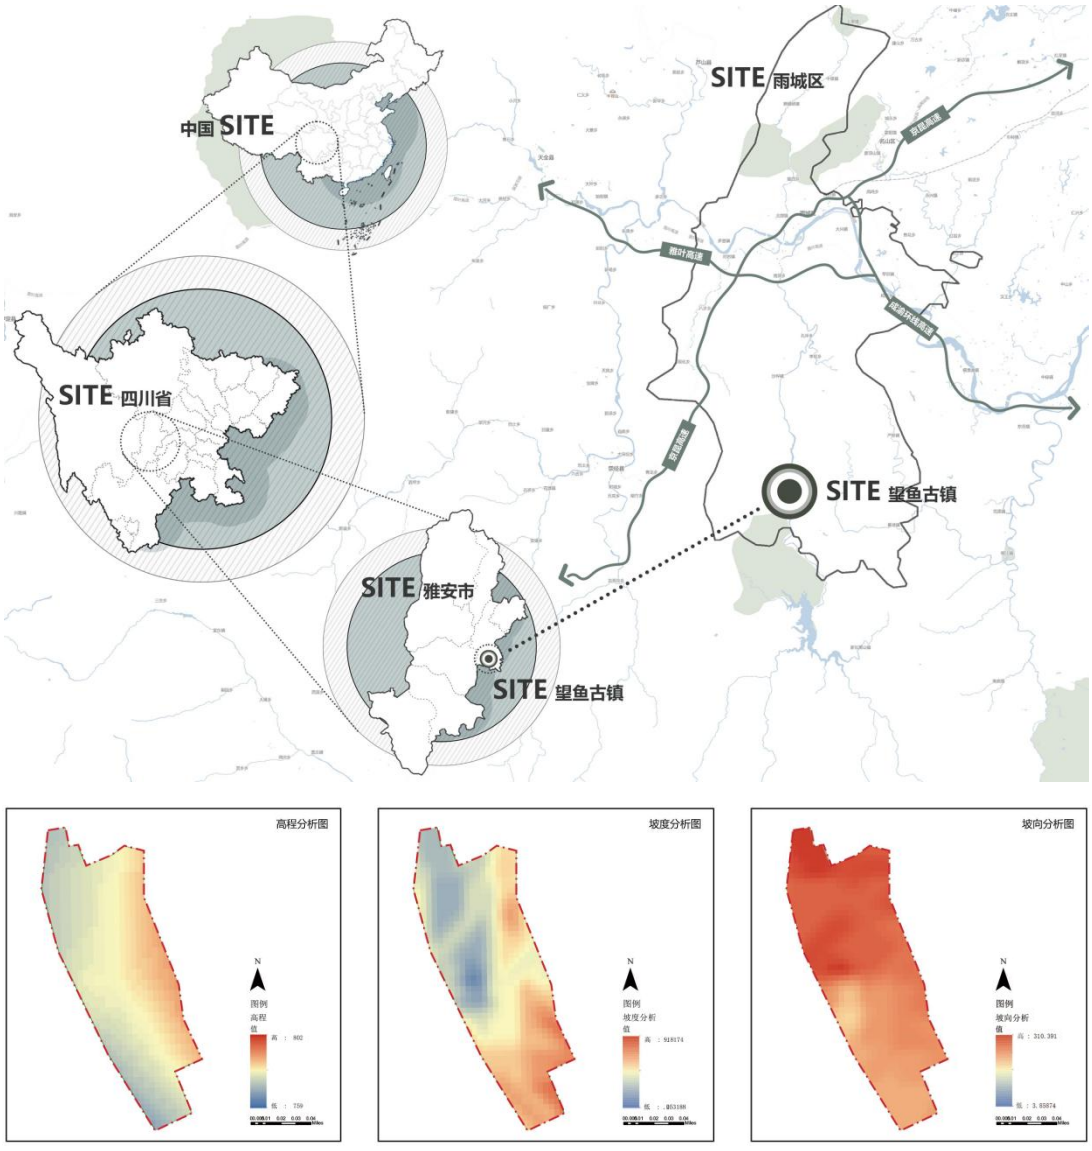


图 1 望鱼古镇区位和地理信息分析

图片来源：笔者自作

本文选择望鱼古镇作为实验区，望鱼古镇位于中国四川省雅安市雨城区，古镇地势起伏大，区位和地形分析见图 1。古镇地势东高西低，其中建筑依势而建，以住宅居多，部分多层建筑底层用于商业上层用作居住。建筑构造以木材作为主

要材料，外围护墙体采用木板墙或者竹编泥墙，采用石材作为首层地面和建筑底部的围护材料。建筑临水一面还采用了四川独特的吊脚楼形式双坡、出檐深远，天井四面屋檐相连。

选择望鱼古镇作为本文实验区的理由有：望鱼古镇传统建筑的结构类型均为穿斗式木结构，木材作为了其主要的构造材料。其在所处环境、建筑构造特点等方面对于中国西南地区传统建筑具有代表性；便于有针对性的验证损伤检测系统在实际使用场景中的有效性；最后，望鱼古镇在 2013 年被列入第二批“中国传统村落名录”，其具有较高的研究价值。

2.2 现状损伤调查

表 1 望鱼古镇损伤展示

位置	现状损伤		
柱子			
	Decay	Crack	Crack+Decay
墙体			
	Pest	Decay	Crack+Knot

环境潮湿和地震是造成望鱼古镇传统建筑木构件损伤的主要原因，部分实拍损伤图片在表 1 中展示。望鱼古镇所在的雅安至古以来多雨，空气潮湿，日照时间短，建筑木构件因受潮频发腐朽或虫蛀。2013 年雅安发生 7.0 级强烈地震，望鱼古镇距离的震源地直线距离大约为 100 公里，推测烈度大概在 5 度左右。个别建筑物的墙壁出现了倾斜、下沉、倒塌和开裂等现象。为展开后续的损伤检测系统实验，我们在望鱼古镇对目测具有损伤的木构件进行了拍摄，使用的拍摄设

备为 iphone14。共拍摄了 24 张图片和 5 条视频。

3.数据集

3.1 数据采集

数据集名为“传统建筑木构件损伤数据集”，图像采集自中国西南地区传统民居的木构件（梁、板、柱）。使用 Nikon Z30 相机（分辨率 5568×3712 像素）针对同一损伤区域进行多维度采集：

（1）时间维度：涵盖不同时间段（清晨、正午、黄昏）的自然光变化；

（2）环境维度：包含顺光、逆光及侧光条件下的成像；

（3）空间维度：正视、侧视、仰视及局部特写视角（距离目标 0.3-1.5 米）。

表 2 各类木构件损伤的成因、表征及高发部位

序号	名称	表征	成因	常见出现部位
D1	裂缝	表面或端面纵向、斜向或放射状裂隙裂。边缘因氧化呈深褐色，内部可见浅黄色新鲜木质	木材干燥时水分流失导致收缩不均，内部应力超过强度引发开裂；外部荷载、温度变化或结构变形加剧裂纹	梁、檩条、柱头、柱脚
D2	节子	表面颜色较周边木质通常更深，形状一般为圆形、椭圆形或者不规则形状	生长过程中，枝条与主干相交，局部枝条生长异常；病虫害导致的异常生长	梁、柱子、板材
D3	腐朽	表面颜色为黑褐或棕红，分布白色或黄色絮状菌丝及霉斑；严重时可见网状龟裂、蜂窝状孔洞或海绵状疏松结构	真菌（如木腐菌）分解木质纤维素，导致木材丧失力学性能，木构件可能会变得松散，失去支撑性能	柱脚、屋檐椽、飞椽、斗拱隐蔽面
D4	虫蛀	表面可见针孔状虫眼，外观为圆形或椭圆形小孔，内看有蛀道，孔口外伴随木屑或粉末堆积	昆虫（如白蚁、粉蠹）在木材内产卵，幼虫蛀食纤维素形成孔洞	榫卯节点、望板、椽子背面



图 2 木构件损伤表征

图片来源：笔者自作

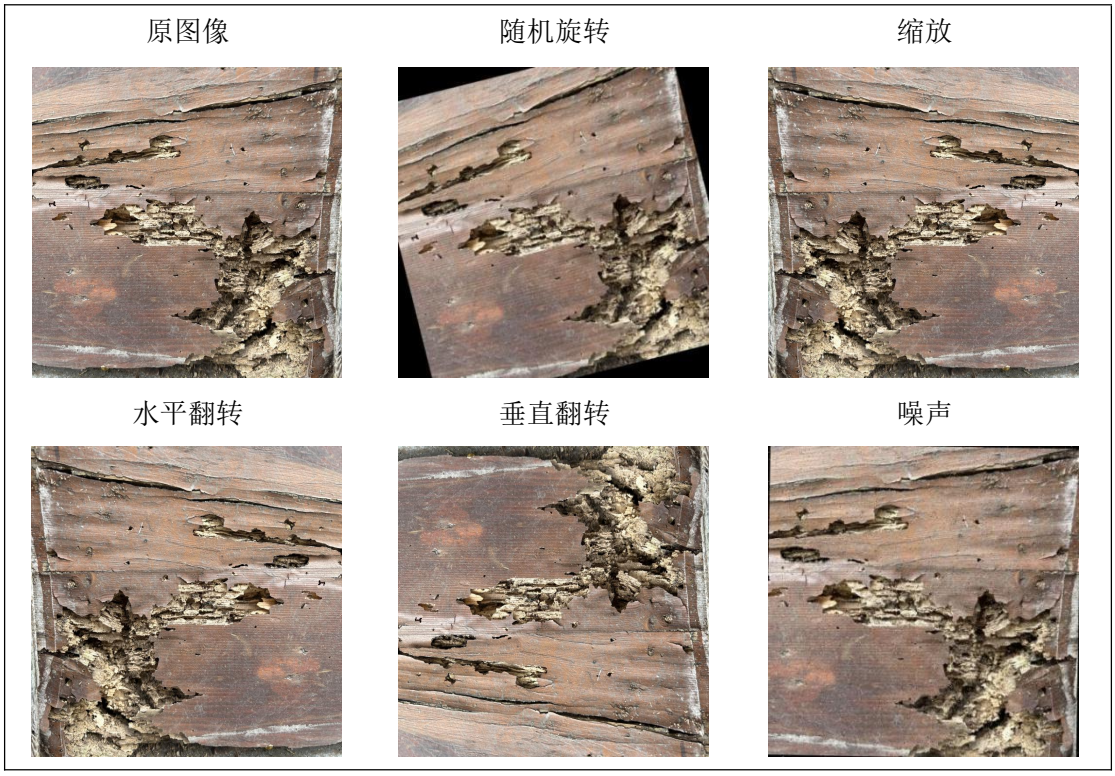


图 3 数据增强策略展示

图片来源：笔者自作

本文提供的数据集包含了裂缝、节子、腐朽、虫蛀四个损伤类别，这些木构件损伤表征在图 2 中进行了展示。数据集中的每张图片都对应了一个标签文件，以便用于模型训练和性能评估。在表 2 中详细描述了四类损伤的表征和成因，为数据标注工作提供了依据。

3.2 数据集制作

数据集的标注工作在 Roboflow 平台上完成，标注工作由 2 名标注员共同完成并交叉验证，确保边界框精准的包住损伤区域，以及边框被标注了正确的类别标签。边界框和类别标注完成后，进行预处理统一缩放至 640×640 像素。

原始数据集中共有 1246 张图像，划分为训练集（926 张）与验证集（230 张）比例为 8:2。为提升数据集的数据量，本研究实施了以下数据增强方法：一是图像空间变换，图像随机旋转（±30°）、缩放（0.8-1.2 倍）、水平/垂直翻转；二是噪声注入，在图像中添加随机噪声（σ=0.05）模拟低光线环境下的干扰；数据增强后训练集的等效样本量提升到了 2783 张，在图 3 中展示了上述几种增强策略的实际效果。数据增强完成即可导出数据集，其格式要严格遵循 YOLO v8 要求的数据集格式。

3.3 数据集特征分析

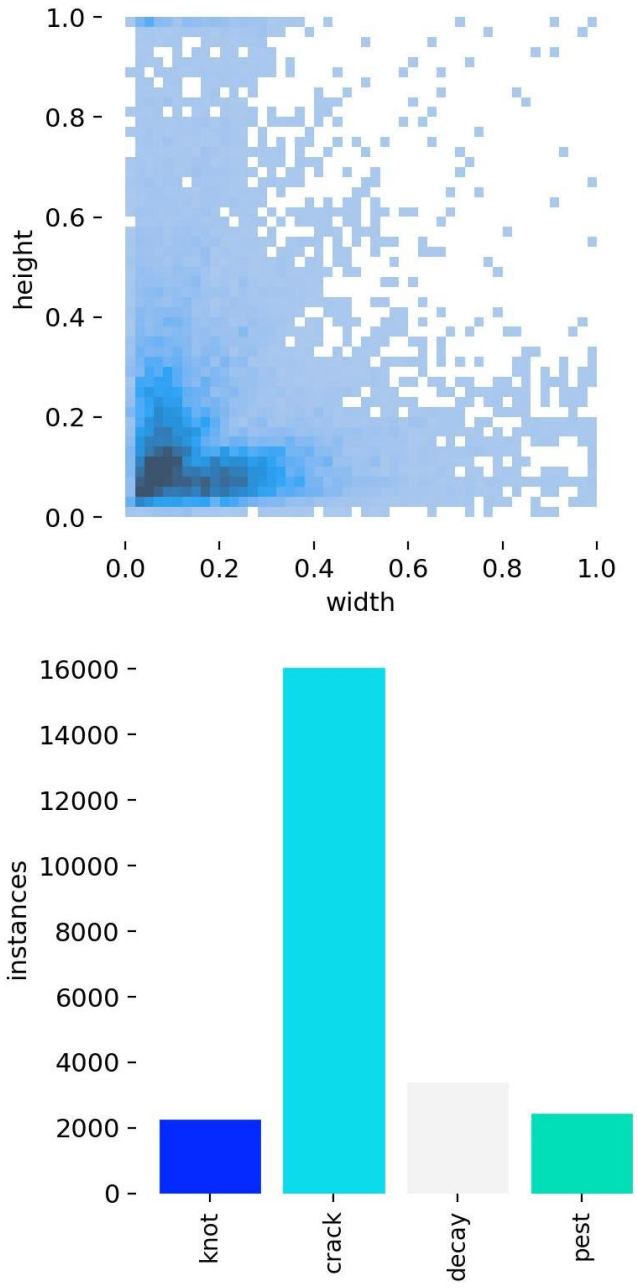


图 4 目标大小分布矩阵（上）样本量统计（下）

图片来源：笔者自作

观察本研究构件的数据集以及图 4 所示分析结果，我们可以总结出以下对于损伤检测任务具有挑战性的特征：一是同一类型损伤的表征具有多样性，这是因为同一类型损伤往往会因为成因不同、拍摄光线角度不同等因素呈现出显著的表观差异。二是开裂样本量占比过高（80%的样本是开裂），影响了数据集样本的平衡性。三是小目标占比高，例如 70%虫蛀区域面积<50×50 像素。四是老旧构件表面污渍可能会对腐朽检测造成干扰。

4.损伤检测系统开发

本章节详细介绍了“中国西南地区传统建筑木构件损伤检测系统”的设计框架，详细的介绍了系统中的关键技术、改进与创新。这些技术为系统高效、精准的损伤检测和记录提供了支持，以下分别介绍这些部分的内容。

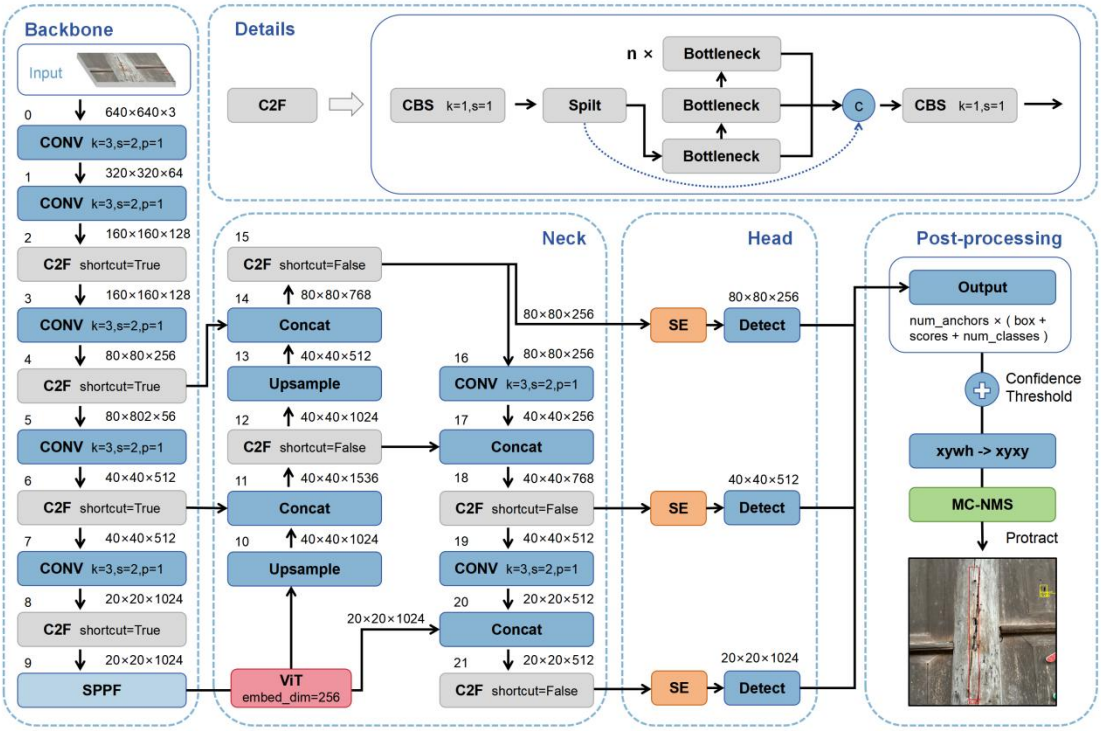


图 5 改进目标检测模型结构

图片来源：笔者自作

4.1 计算机视觉目标检测算法

目标检测是损伤检测系统的核心功能，其准确性和效率直接影响系统的实际应用效果。本系统基于 YOLO v8 目标检测模型，该模型是由 Ultralytics 开发并发布，在业内有名的 YOLO v5 架构上进行了拓展。其架构可分为以下三部分，主要用于提取特征的 Backbone 部分，采用了 C2f 作为了基本模块，在降低参数量的同时提高了特征提取能力。除此之外，还加入了深度可分离卷积等改进技术。用于提高特征的表示能力的 Neck 部分对 Backbone 不同层的特征图进行融合。整个模型的头部 Head 部分包括了一个检测头和一个分类头，将最终的回归和分类任务分离执行。值得一提的是 YOLOv8 改用了 Anchor-free 机制直接预测目标的中心点偏移量和宽高缩放值，这样的机制较早期的 YOLO 系列的预设锚框机制有效降低了模型的权重参数[36, 37]。

YOLO v8 的输入图像尺寸为 640×640×3，图像经模型推理后返回目标检测的具体信息，包括位置、置信度和类别。位置信息巧妙的依赖了不同特征尺度（20×20、40×40、80×80 的网格单元）的信息生成了多个候选锚框，这样的设计确保模型对于不同大小的目标，都能够有效地进行检测和定位。模型输出预测张量并不意味着目标检测任务的结束，想要得到准确的检测结果还需要对输出张量进行后处理，进一步过滤掉冗余的检测框以提高检测精度。YOLO v8 的后处理主要包括转换边界框坐标、过滤无效预测、去除冗余框三个步骤。模型最终会输出目标的边界框坐标、类别和置信度。可以说用于去除冗余框的类别感知非极大值抑制（NMS）算法是后处理的核心步骤，其基本操作是以置信度最高的预选框为基准，计算其与其他该类型候选框的 IoU，然后删除超过 IoU 阈值的框。在所有框被处理完之前会重复上述核心步骤，最终保留下来的预测框即为输出结果。为了缓解类别感知 NMS 在同一损伤区域表征差异大，细长裂缝数量多的检测任务中的不足，我们进一步提出了混合聚类的非极大值抑制（MC-NMS）。MC-NMS 结合了传统 NMS 和聚类算法的优点，核心创新点是通过类别分组、特征聚类和预选框融合等步骤，降低重复检测的问题。具体内容将在后续章节详细介绍。

IoU (Intersection over Union)、AP (Average Precision) 和 F1 分数是 YOLO v8 中三个用于评估模型性能，量化模型的准确性、精度和召回率[38]的重要评估指标。IoU 是指两个框交集区域的面积与它们并集区域的面积之比，计算方法为公式 1 。谈到 AP 就不得不提到 Precision 和 Recall 这两个基本指标。Precision 是指真正例（TP）占所有预测为正（TP + FP）的样本的比例公式 2。Recall 表示的是所有真实为正（TP + FN）的样本中，被模型正确预测为正(TP)的比例公式 3。AP 巧妙的将两个基本指标结合了起来，值为某个类别召回率和精度曲线下的面积，因此平均精度均值 mAP(Mean Average Precision)也变得很好理解，即为每一个类别 AP 的均值。在实际应用中 mAP 的值通常是在特定的 IoU 阈值下进行计算得到的，就比如 mAP@50 表示模型在 IoU 阈值在 0.5 时的平均精度均值，mAP@50-95 表示在不同 IoU 阈值（从 0.5 到 0.95，步长为 0.05）上的平均 mAP。此外，F1 分数也是一个用于综合评估 Precision 和 Recall 的指标，通过它可以更加全面地衡量模型的性能。F1 分数是 Precision 和 Recall 的调和平均，计算方法为公式 4。

$$\mathrm{IoU} = \frac{\mathrm{overlappingarea}}{\mathrm{unionarea}} \quad \text{公式 1}$$

$$Precision = \frac{TP}{TP+FP} \quad \text{公式 2}$$

$$Recall = \frac{TP}{TP+FN} \quad \text{公式 3}$$

$$F_1 = 2 \times \frac{\mathrm{Precision} \times \mathrm{Recall}}{\mathrm{Precision}+\mathrm{Recall}} \quad \text{公式 4}$$

和 YOLO v5 一样 Ultralytics 发布了五种用于目标检测任务的 YOLO v8 的子模型，表 2 详细描述了其相互之间的区别。

表 3 YOLO v8 子模型配置及描述

模型	描述	mAPval（50-95）	推理速度 CPU ONNX (ms)	参数量（M）
YOLO v8n	最小的模型，适合资源有限的环境，但精度相对较低	37.3	80.4	3.2
YOLO v8s	具有较好的检测性能，适合普通应用	44.9	128.4	11.2
YOLO v8m	速度和精度之间达到了较好的平衡	50.2	234.7	25.9
YOLO v81	有较高的精度，适合需要高准确度的应用场景	52.9	375.2	43.7
YOLO v8x	有最高的精度，但需要更多的计算资源，推理速度最慢	53.9	479.1	68.2

综合考量模型精度与效率的平衡情况，YOLO v8m 不失为一个良好的基础模型，本文的改进及训练工作均基于此开展，为提高模型在复杂场景下的表现，在模型结构里引入了注意力机制，改进后的目标检测网络结构如图 5 所示，相关内容会在“注意力机制”部分进行详细探讨。

4.2 注意力机制

本文引入了两种注意力机制：Vision Transformer (ViT)[39] 和 Squeeze-and-Excitation (SE)[40]，用于加强 YOLO v8 在中国西南地区传统建筑木构件损伤检测任务中的表现，其中采用了这两种注意力机制提高全局特征建模能力以及通道特征选择能力，以此增强模型在面对复杂场景时适应性和准确率。

4.2.1 Vision Transformer (ViT)的引进

本文将 ViT 模块放入 YOLO v8 的特征提取过程中，处于 SPPF（Spatial Pyramid Pooling-Fast）层的后边。ViT 模块可以使用多头自注意力机制(Multi-Head

Self-Attention, MHSA)提取全局特征，并弥补卷积运算只能局限在局部感受域的缺陷。

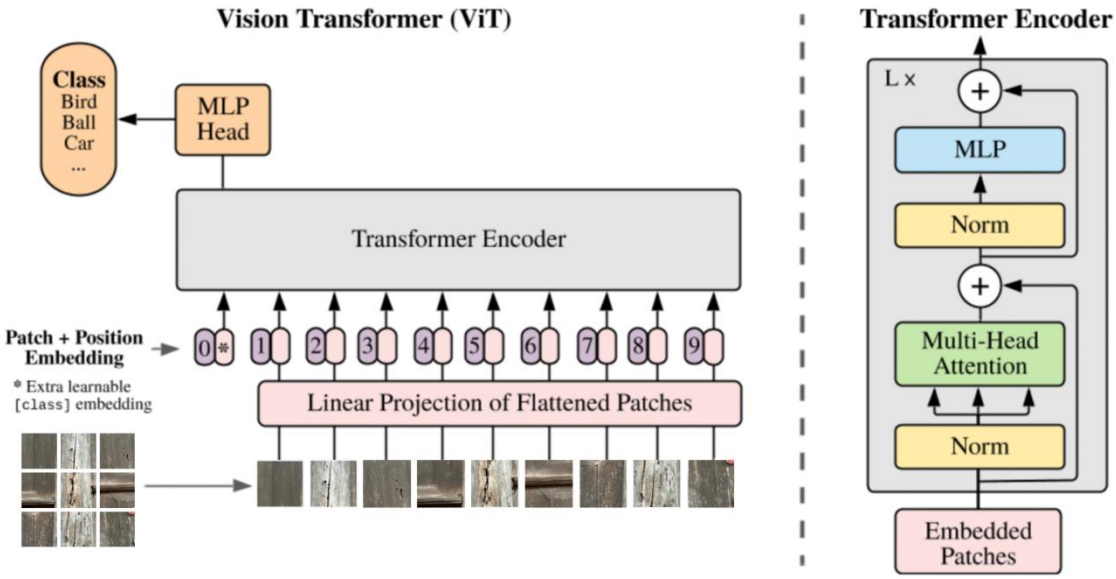


图 6 ViT 模块处理流程

图片来源：参考自 ViT 原文章[39]

ViT 模块的输入为 SPPF 模块输出的特征图。图 6 展示了 ViT 的处理流程，模块首先将输入特征图划分为固定大小的 patch（如 16×16），每个 patch 通过线性变换映射到高维嵌入空间。然后，这些特征通过 Transformer 编码器进行处理，捕获不同 patch 之间的全局关系。

4.2.2 Squeeze-and-Excitation (SE) 的应用

SE 模块是改进 YOLO v8 网络中三个检测头前放置的轻量级通道注意力机制，在此基础上对不同尺度的特征通道的权重进行加权。SE 注意力模块是利用动态调参数提升通道间融合度，提高主干网提取的目标信息，并且能减低其他非目标信息的影响，处理流程如图 7 所示。

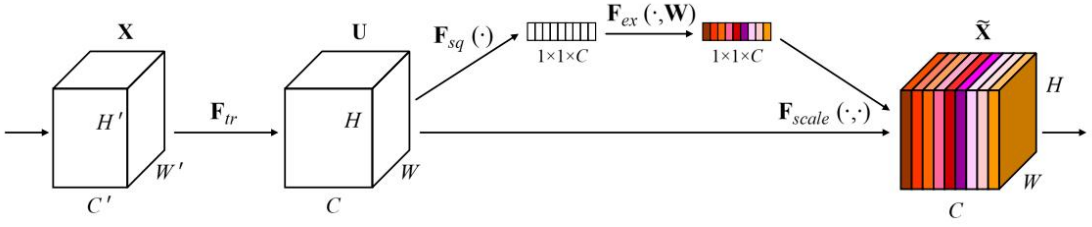


图 7 SE 模块处理流程

图片来源：SE 原文章[40]

SE 模块通过公式 5 实现通道加权，X 表示输入特征图，GAP 为全局平均池化，W_1和 W_2分别为两个全连接层的权重矩阵，σ为 Sigmoid 激活函数，z 为通

道权重。最终，通道权重 z 对输入特征通道进行重加权，增强模型对小目标（如虫蛀区域）的检测能力，并提高对多样化腐朽类型的适应性。

$$\mathbf{z} = \sigma(\mathbf{W}_2 \cdot \mathrm{ReLU}(\mathbf{W}_1 \cdot \mathrm{GAP}(\mathbf{X}))) \quad \text{公式 5}$$

4.2.3 注意力机制的协同作用

通过 Vit 模块的全局建模，模型在特征提取阶段能更好的把握全局信息，使网络具有更强的上下文意识；通过 SE 模块对通道权重进行调节，从而可以在检测头阶段获得更好的效果。

（1）ViT 模块能获取全局特征信息，在目标密集且背景复杂的情况下较少出现漏检的情况。

（2）SE 模块能够根据检测头前的通道的特征，对关键通道特征进行动态增强，使得模型对小目标检测效果提升。

4.3 混合聚类非极大值抑制(MC-NMS)

为了改善 YOLO v8 使用的类别感知 NMS 方法的弊端，在此基础上，本文提出一种 MC-NMS 方法。类别感知 NMS 对于存在边界模糊以及重叠损伤区域的预选框抑制上，较容易造成一个损伤区域分割成多个无关联检测框，仅保留最高分框，这会造成重复记录现象和信息丢失现象，而MC-NMS相比与类别感知NMS的优势十分突出。一是能够对对相邻框进行分组，减少了将一个区域分割成多个检测框的情况。二是采用了自动估计簇数的策略，动态适应目标分布。三是将聚类后的加权融合生成精确的目标框，同时保留最高置信度的分数。可以说 MC-NMS 兼具了传统 NMS 的高效性和聚类算法的精细化处理能力。

在目标检测中，假设检测框集合为$\{B_1, B_2, \ldots, B_n\}$，其中每个框$B_i$包括其位置 $\mathrm{box}(x_1, y_1, x_2, y_2)$、置信度分数$s_i$和类别标签$c_i$。对于每个类别 c，首先使用传统的非极大值抑制（NMS）算法去除冗余的重叠框，得到保留的框集合$\mathcal{B}_c = \{B_{c1}, B_{c2}, \ldots, B_{cn}\}$。然后，对于保留框集合中的每个框$\mathcal{B}_i$，计算每个预测框的中心点坐标和尺寸，计算方法为公式 6 和公式 7，并将这些特征(C_x, C_y, W, H)作为每个框的特征向量 Fi 用于后续的聚类操作（DBSCAN）。接下来，使用 DBSCAN 算法对特征向量集合$\{F_1, F_2, \ldots, F_n\}$进行聚类。通过设定邻域半径$\epsilon$和最小点数 minPts，使任意特征向量 Fi，其邻域 $N\epsilon(Fi)$ 定义为满足公式 8 的点集合。其中$|F_i - F_j|_2$为特征向量F_i和 F_j之间的欧几里得距离。如果点的邻

域包含至少 minPts 个点，则该点为核心点，并通过扩展核心点的邻域将其归为同一簇，未归入任何簇的点被标记为噪声点。聚类完成后，会形成 i 个聚类簇$\mathcal{C}_i$，其中s_j为框B_j的置信度分数，box_j为框的位置特征(x_1, y_1, x_2, y_2) 。簇内的每个框会根据其置信度进行加权平均，从而得到该簇的融合框 fused_box，公式 9。每个簇的最终置信度则取簇内所有框的最大置信度值 confidence，即每个聚类后的簇对应一个加权融合后的框和该簇的最大置信度。

$$C_x = \frac{x_1+x_2}{2},\ C_y = \frac{y_1+y_2}{2} \quad \text{公式 6}$$

$$W = x_2 - x_1,\ H = y_2 - y_1 \quad \text{公式 7}$$

$$N\epsilon(F_i) = F_j || F_i - F_j|_2 \le \epsilon \quad \text{公式 8}$$

$$\text{fused_box} = \frac{\sum_{j\in\mathcal{C}_i} s_j \cdot box_j}{\sum_{j\in\mathcal{C}_i} s_j} \quad \text{公式 9}$$

4.4 Exif 文件地理信息解码方案

实地采集的数码照片是用于后期损伤检测任务的基础数据。照片附属的 Exif（Exchangeable Image File Format）文件中包含的地理信息亦具有较高的应用价值。Exif 文件的格式标准是由日本国际相机影像器材工业协会（CIPA）与电子信息技术产业协会（JEITA）联合制定，如今主流的数码成像设备拍摄的照片中都附属了 Exif 文件[41]。Exif 文件里包含的信息极为丰富，涉及拍摄设备参数、拍摄时间以及地理定位等关键信息[42]，本研究考虑到传统建筑木构件损伤检测里损伤位置依靠人工记录存在局限，提出一种借助解码 Exif 文件进行地理信息自动化提取的方法，为损伤检测和地理信息高效低成本结合给出了实施途径。

基于解码 Exif 文件的定位技术主要优势是不依赖外部设备就能达成较高精度的定位，这项技术已在社交媒体、科学研究、行为分析等领域广泛应用。比如 Karwan 等人[43]通过提取道路损伤图像的 GPS 坐标，帮助地方政府进行市政道路维护的自动化管理。Li 等人[44]在小麦病虫害综合管理研究中，将 Exif 文件中的 GPS 信息用于分析拍摄地点的天气和作物生长阶段的关系。Chen 等人[45]利用无人机影像的 Exif 定位信息，将建筑立面检测的配准精度提升至厘米级。上述研究表明，基于解码 Exif 文件的定位技术已经相当成熟。

不过，Exif 文件中包含的 GPS 数据想要投入到实际项目中使用，还需要将

数据转换为合理的格式[46]。解码器在获取 Exif 文件里的 GPS 数据后，要把它转变为能被 Google Maps、Google Earth 或者 ArcGIS 等系统接纳的格式，然而现有的工具没办法直接转换 Exif 文件中的 GPS 数据[46]，鉴于这种情况，我们设计了一套以 Python 为基础的 GPS 数据自动化处理程序，程序的核心有数据解析、坐标转换以及数据集成这三大模块。程序会先自动识别 JPEG 附属的 Exif 文件，从所有数据里提取出原始的 GPS 信息，接着运用 WGS-84 地理坐标系对 GPS 信息做转换，把度分秒格式转变为十进制经纬度格式，保证它和地理信息系统相互兼容，最后把解析后的经纬度坐标、木构件损伤类型、置信度等检测结果整合为一个包含坐标、损伤属性的表格，给后续的空间分析提供标准化输入。

4.5 基于 Pyside2 的损伤检测系统开发

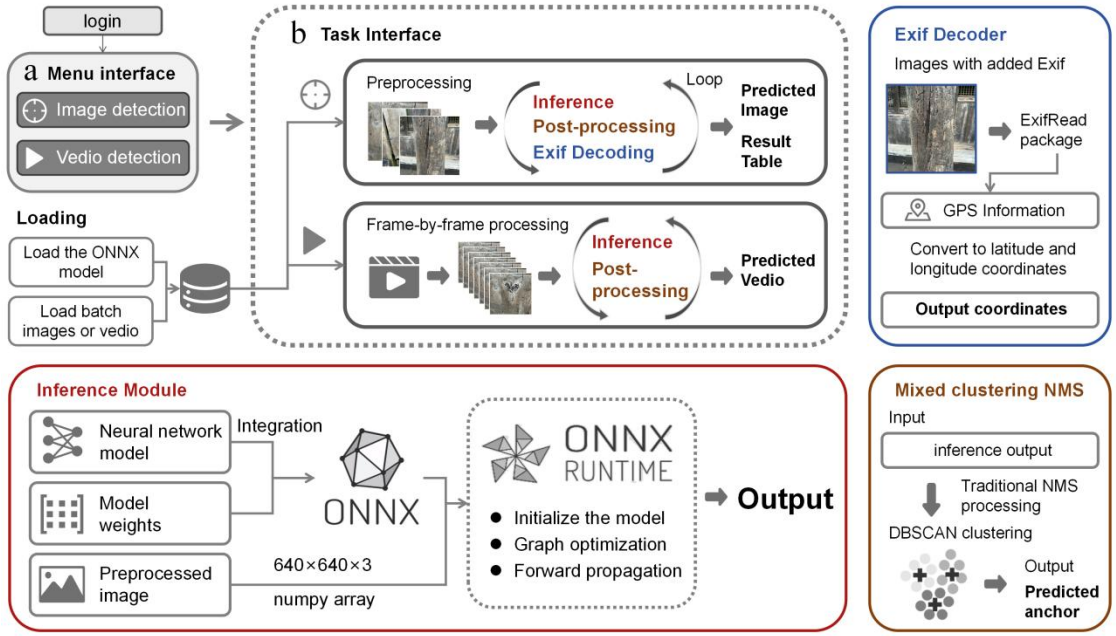


图 8 传统建筑木构件损伤检测系统设计框架

图片来源：笔者自作

本研究借助 PySide2 框架研发出一套传统建筑木构件损伤检测系统，来为中国西南地区的建筑保护部门打造高效的损伤调查及记录工具，此系统融合了改进版 YOLO v8 目标检测模型以及地理信息解码模块，拥有图像与视频检测功能，工作人员可经由友好的用户界面，轻松实现木构件损伤的自动检测以及损伤位置的精确记录。 系统依照模块化设计，其设计框架如图 8 所示，系统在功能模块方面主要囊括图像检测模块与视频检测模块，用户登录成功进入菜单界面后，可依据需求选择不同的功能模块，这两个模块都可借助滑块的调节来改变置信度阈值和 IoU 阈值。在图像检测模块中，用户需要上传单张或多张图像文件，还要载

入一个 YOLO v8 的 ONNX 版本模型，ONNX 模型可以通过 Ultralytics 提供的转换程序转换 YOLO v8 模型得到[47]。用户完成图像与模型加载操作后，可凭借点击“推理”按钮来促使系统开展检测工作，在推理的进程当中，进度条会依据实际情况实时更新，以此呈现出处理的具体进度。出于契合用户预览预测后图像的需求这一考量，特意在系统里增添了切换功能，当推理操作结束后，用户可点击“切换”按钮，在窗口中展示检测得出的结果。也可点击“保存”按钮，把检测结果导出至本地。系统所导出的检测结果囊括以下内容： 其一，检测之后的图像文件，该图像上标注有损伤预测框、损伤类型以及置信度。 其二，损伤记录表格，此表格含有图像名称、经纬度坐标、损伤类型以及置信度等信息，它可直接导入 GIS 之中，并被转换为 Shapefile 格式，用于可视化分析。

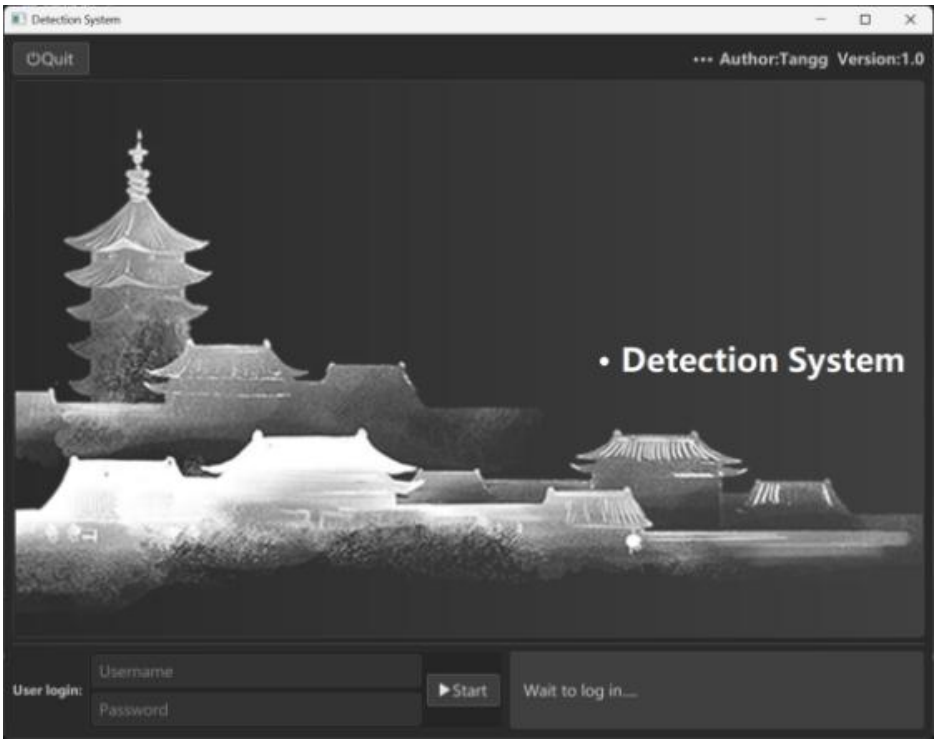


图 9 登录界面

图片来源：笔者自作

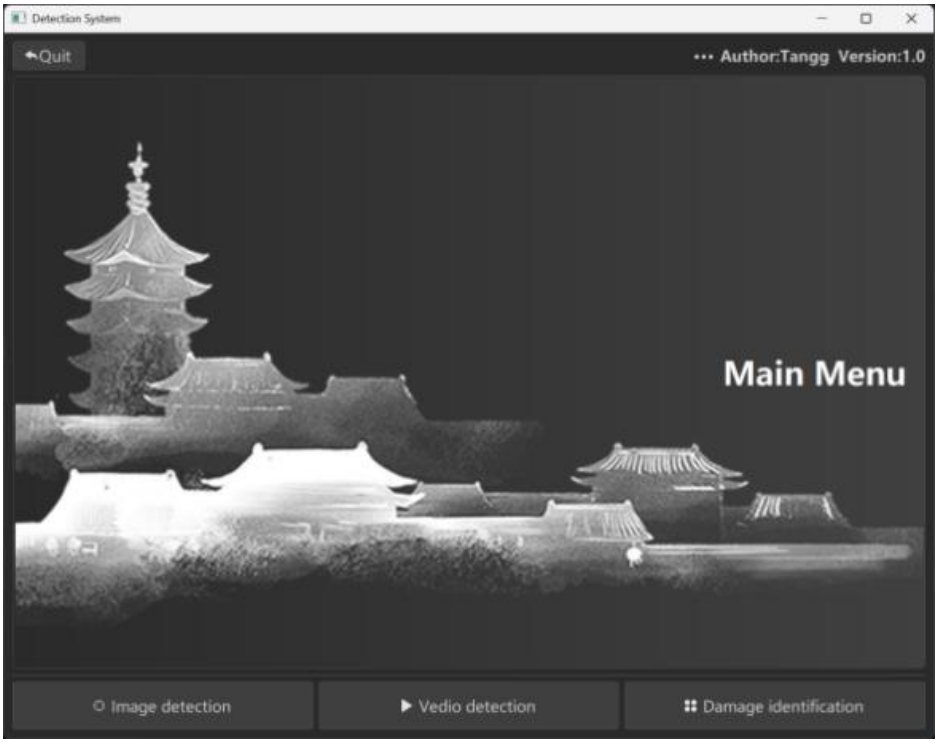


图 10 菜单界面

图片来源：笔者自作

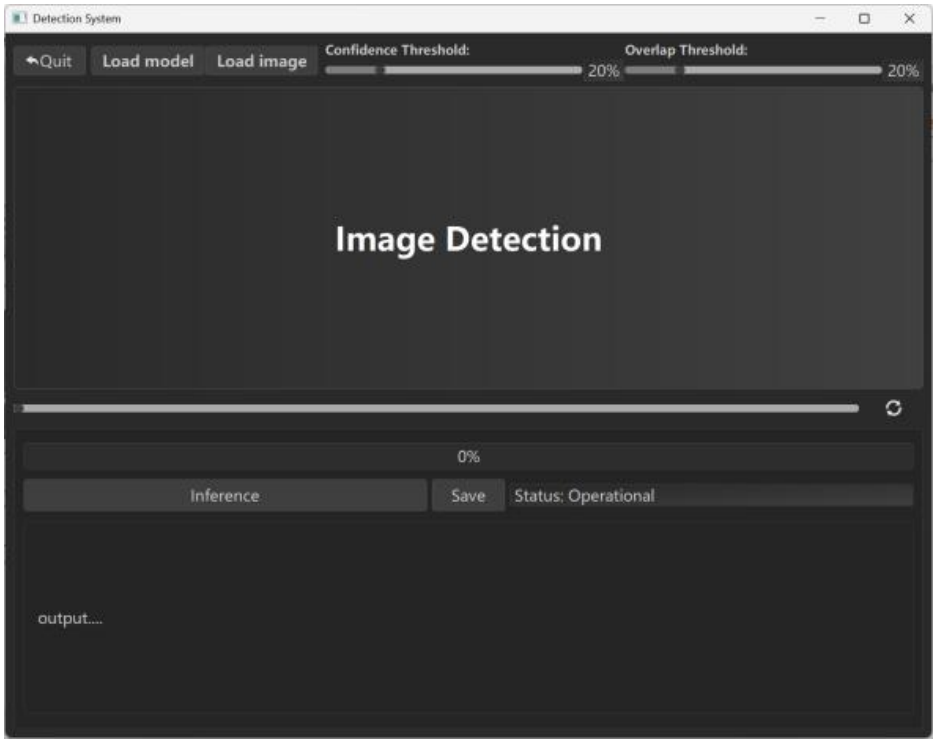


图 11 图像检测功能界面

图片来源：笔者自作



图 12 视频检测功能界面

图片来源：笔者自作

在视频检测模块里面，当用户把视频文件加载好之后，可点击“播放”来对视频进行预览，在成功加载视频以及 ONNX 模型后，用户可点击“推理”按钮开启检测，系统会对视频里的木构件损伤进行逐帧检测，并且实时更新进度条以此来展示处理的进度，推理完成以后，用户可点击“切换”按钮去预览检测之后的视频，或者借助点击“保存”按钮将处理后的视频导出到本地。该系统运用 PySide2 框架达成了多线程的用户界面，保证在推理过程中界面可以维持响应，登录界面、菜单界面以及两个功能界面的视觉呈现如图 9-11 所示。

5.结果与讨论

本章节将围绕改进模型的训练过程、性能验证以及传统建筑木构件损伤检测系统的使用效果三个方面展开讨论。重点分析了改进模型在传统建筑木构件损伤数据集上的训练表现。为了直观的展示到改进模型的优越性，本研究还分析了其相较于原始 YOLO v8 模型在检测任务中的优势。然后通过了模型关注区域对比这样一个有趣的实验进一步评估 SE 和 ViT 注意力机制对模型性能的贡献。最后在中国雅安市望鱼古镇传统建筑群的实地实验中，验证了系统在实际场景中的有效性。

5.1 改进模型的训练与性能验证

本研究为了降低训练的世间和加快模型收敛，在训练前先使用了迁移学习技术将 YOLO v8m 预训练权重迁移到了改进模型中，即只有四个注意力机制层参数保持了初始化状态。训练过程中，采用了冻结与解冻权重相结合的策略，详细的策略如下：

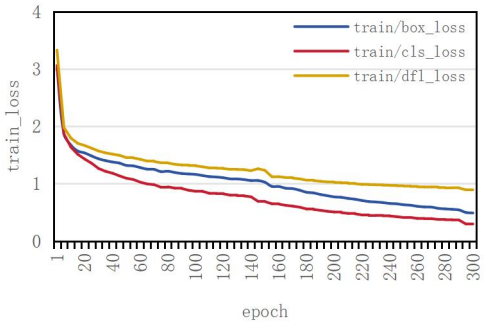
（1）冻结阶段：在训练的前 150 轮，冻结模型的前十层权重，保留 Backbone 模块的特征提取能力。这个阶段重点训练的是高层权重以及注意力层权重，这样可以防止注意力层混乱的初始权重影响其他具备特征提取能力的预训练权重。

（2）解冻阶段：在冻结阶段完成后，解除所有层的冻结状态继续训练 150 轮。解冻阶段允许全部权重参与更新，进一步提升整体模型性能。

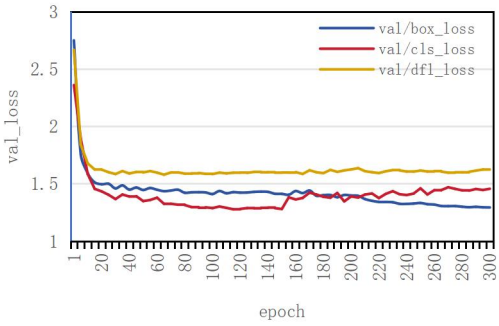
训练过程中，输入图像尺寸为 640×640×3，批量大小为 32，优化器选择了 AdamW，并动态调整学习率。通过迁移学习和分阶段的训练策略，模型在较小的训练成本下实现了性能提升。模型训练工作是通过笔记本电脑连接 AutoDL 算力云平台提供的服务器完成的。模型训练的软件硬件配置如下：cpu(20 vCPU AMD EPYC 7642 48-Core Processor),一个 GPU(NVIDIA RTX 3090（24GB）),以及 32GB 的 RAM。操作系统是 Linux,使用到的深度学习框架是 PyTorch,版本 2.5.1,软件环境依赖有 Python 3.12,CUDA 12.4，具体配置如表 4 所示。

硬件配置	描述	软件配置	描述
GPU	NVIDIA RTX 3090（24GB）	操作系统	Windows10
CPU	AMD EPYC 7642 48-Core Processor	PyTorch	2.5.1
RAM	32GB	Python	3.12
		CUDA	12.4

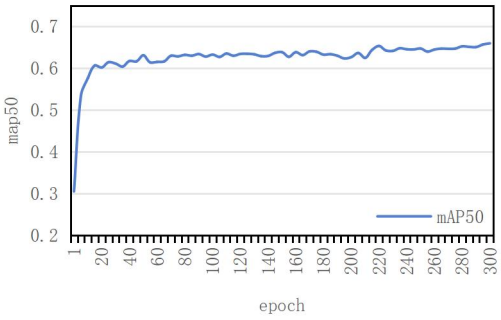
表 4 本研究用到的硬件和软件规格


train/box_loss
train/cls_loss
train/dfl_loss
train_loss
epoch

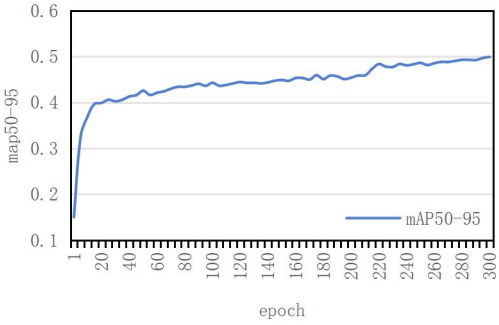
(a)


val/box_loss
val/cls_loss
val/dfl_loss
val_loss
epoch

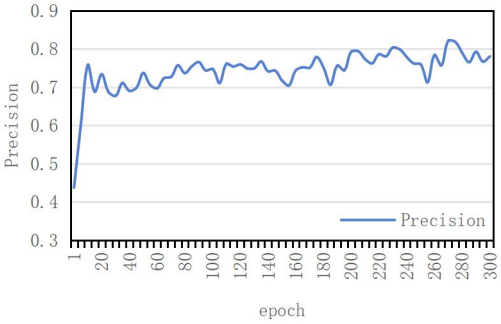
(b)


mAP50
map50
epoch

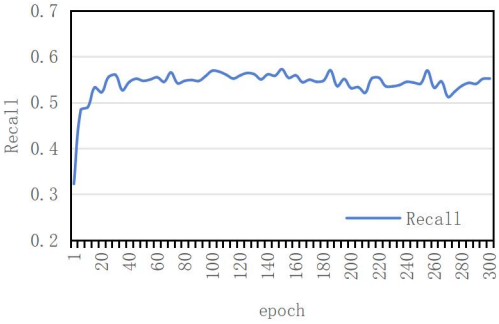
(c)


mAP50-95
map50-95
epoch

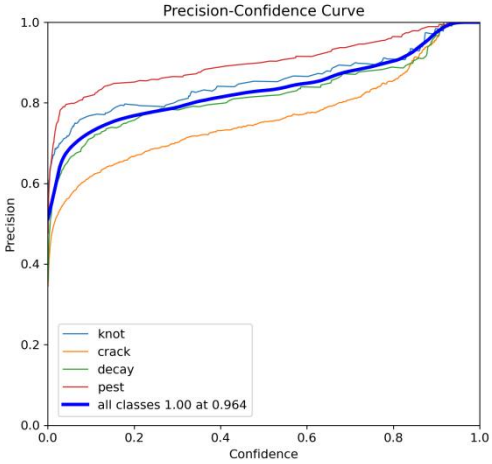
(d)


Precision
Precision
epoch

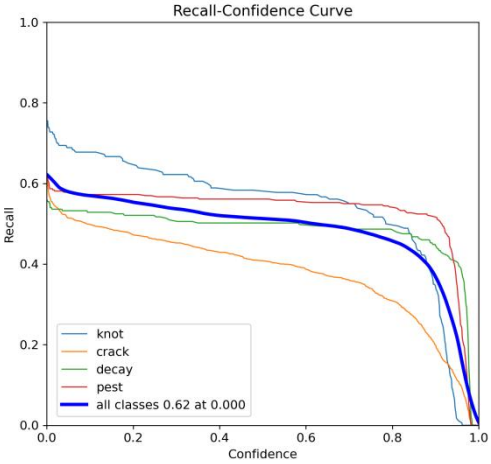
(e)


Recall
Recall
epoch

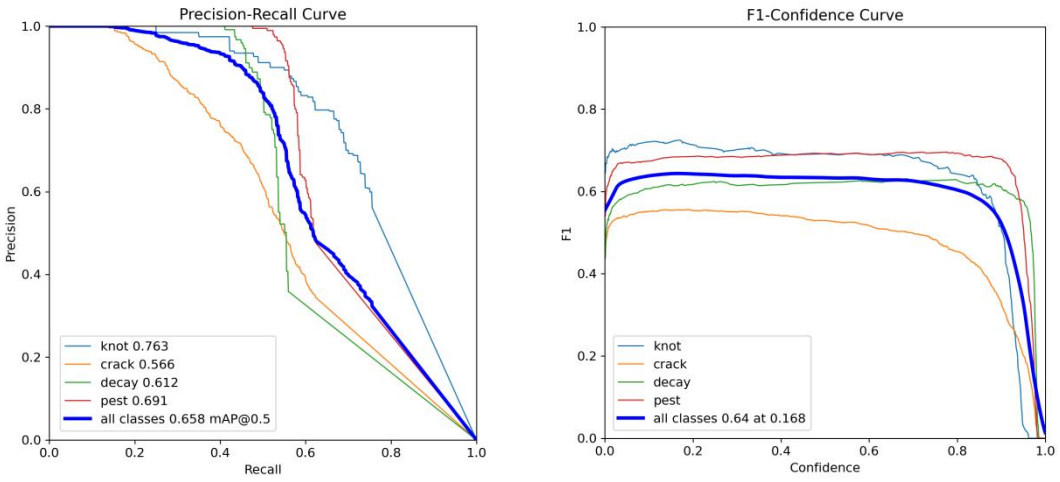
(f)


Precision-Confidence Curve
Precision
Confidence
knot
crack
decay
pest
all classes 1.00 at 0.964

(g)


Recall-Confidence Curve
Recall
Confidence
knot
crack
decay
pest
all classes 0.62 at 0.000

(h)



(i) (j)

图 13 改进模型的训练记录

图片来源：笔者自作

本研究的检测任务具有背景复杂、损伤表征差异显著性小且小目标比例较高等特点，这对目标检测模型提出了较大的挑战。改进后的 YOLO v8 模型经过冻结和解冻共 300 轮训练后实现了收敛，其在测试集上的 mAP50 达到了 0.658，mAP50-95 达到 0.5。训练结果表明，改进模型能够有效学习到损伤目标的特征，并拥有不错的检测精度。

我们观察图 13 中 a、b 两图可以发现训练集和验证集的边界框损失（box_loss）、分类损失（cls_loss）和特征点损失（dfl_loss）均表现为稳步下降，并在 220 轮后趋于收敛。这说明了模型在目标位置回归和类别预测上均取得了良好的优化。

图 13 中的精度置信度曲线（e）和召回率置信度曲线(f)分别显示了，在置信度为 1 和 0 时，精度和召回率的达到最大值 0.964 和 0.62。我们进一步分析 F1 分数曲线（j），能观察到改进模型在四类目标的综合检测能力上具有较高的均衡性，F1 分数在置信度等于 0.168 时达到了最大值 0.64，这进一步验证了模型具有较好的稳定性和分类性能。

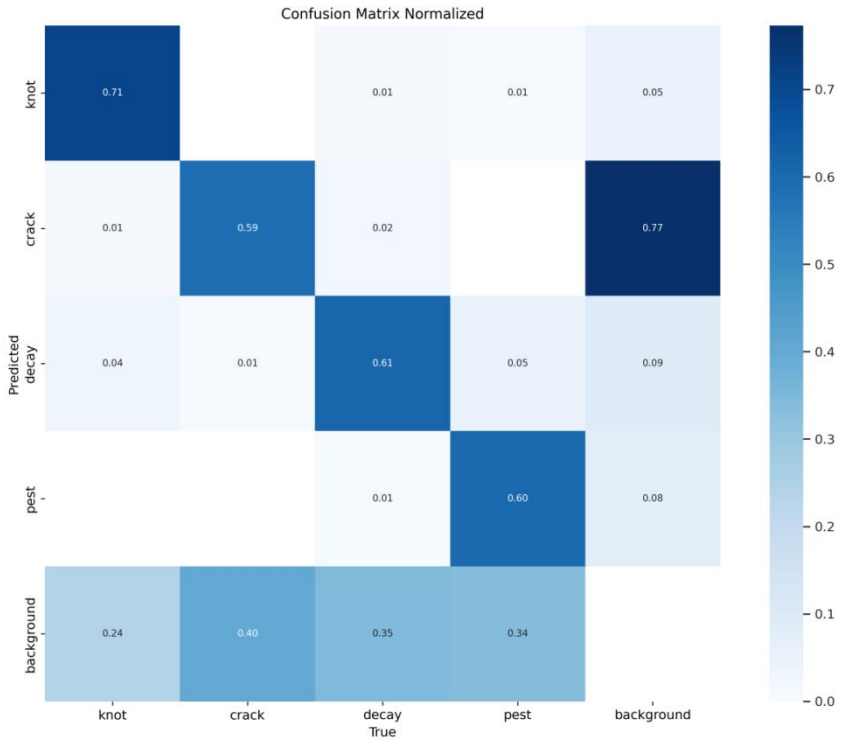


图 14 改进模型在验证集上的混淆矩阵

图片来源：笔者自作

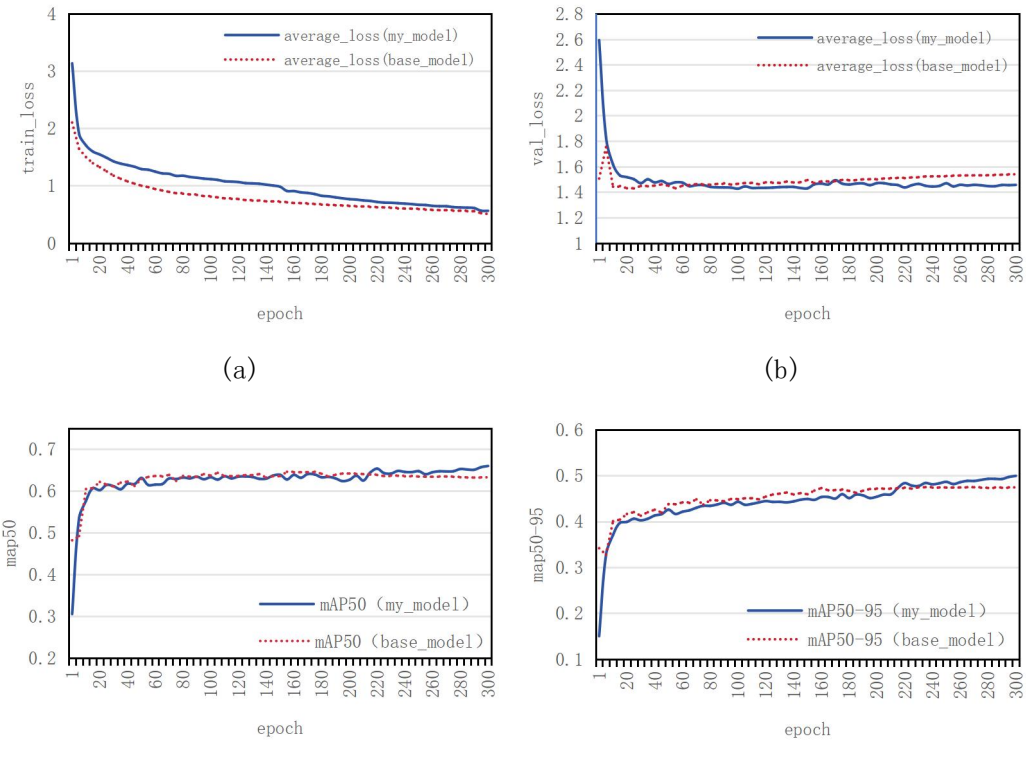


图 15 改进模型与原始模型性能对比

图片来源：笔者自作

图 14 展示的是混淆矩阵结果，我们可以发现模型在四类损伤类型（节子、开裂、腐朽、虫蛀）的检测上均表现出较好的分类能力。其中节子的检测精度较高，检测结果表现出了较低的误报率（FP）和漏报率（FN）。腐朽和虫蛀两类，由于特征差异性较小且容易受到背景干扰以及小目标概率较大，造成了模型的分类混淆情况略高，但仍保持在可接受范围内。模型在检测裂缝时和背景出现了一定的混淆，这与木材拼接处的缝隙与裂缝表征相似导致模型误检有关。

结合以上内容，我们可以得出改进模型能够胜任中国西南地区传统建筑木构件损伤检测任务，并能够在其中表现出较好的鲁棒性的结论。当然这些实验也证明了模型不仅能够通过优化损失函数来提升检测性能，还能在复杂背景下准确识别到损伤目标。

5.2 改进模型与原始模型性能对比

在传统建筑木构件损伤数据集上，改进模型与原始 YOLOv8 模型的性能对比结果表明，改进模型在目标检测任务中具有显著优势。实验中发现，原始 YOLOv8 模型在训练过程中会出现训练平均损失（表示为边界框损失（box_loss）、分类损失（cls_loss）和特征点损失（dfl_loss）的均值）收敛但验证平均损失发散的过拟合现象如图 8，而改进模型通过优化结构和训练策略，显著改善了这一问题，实现了更稳定的拟合性能。观察图 15 可以发现，220 轮以后改进模型 mAP50 和 mAP50-95 性能超过了原始模型，最终，mAP50 和 mAP50-95 较原始模型分别提升了 0.04 和 0.03。结合图 14 和图 16，通过混淆矩阵对比改进模型和原始模型对于四类损伤在分类预测中的表现。可以发现改进模型对于四类损伤识别的真正例（TP）均高于原始模型，误检（FP）和漏检（FN）均低于原始模型，特别是腐朽的识别正确率较原始模型提升了 14%。通过以上分析，可以确认改进模型能够更好的应对损伤背景复杂、表征差异显著性小且小目标比例较高的检测任务。

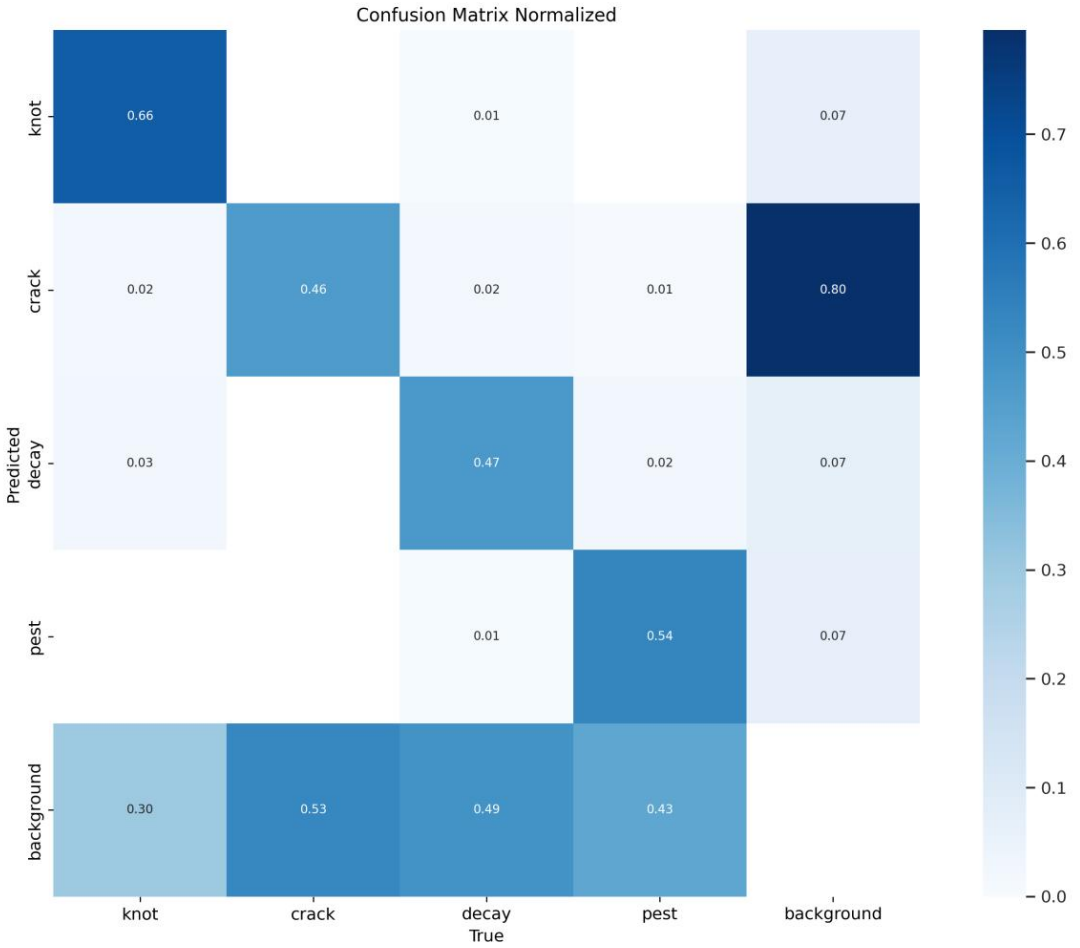


图 16 原始模型在验证集上的混淆矩阵

图片来源：笔者自作

表 5 不同 NMS 后处理方法效果对比

方法	mAP50↑	FI↑	RCD↑	平均耗时（ms）↓
(原始 NMS)CA-NMS	0.55	38	5	278.8
(改进 NMS)MC-NMS	0.57	26	6	334.5

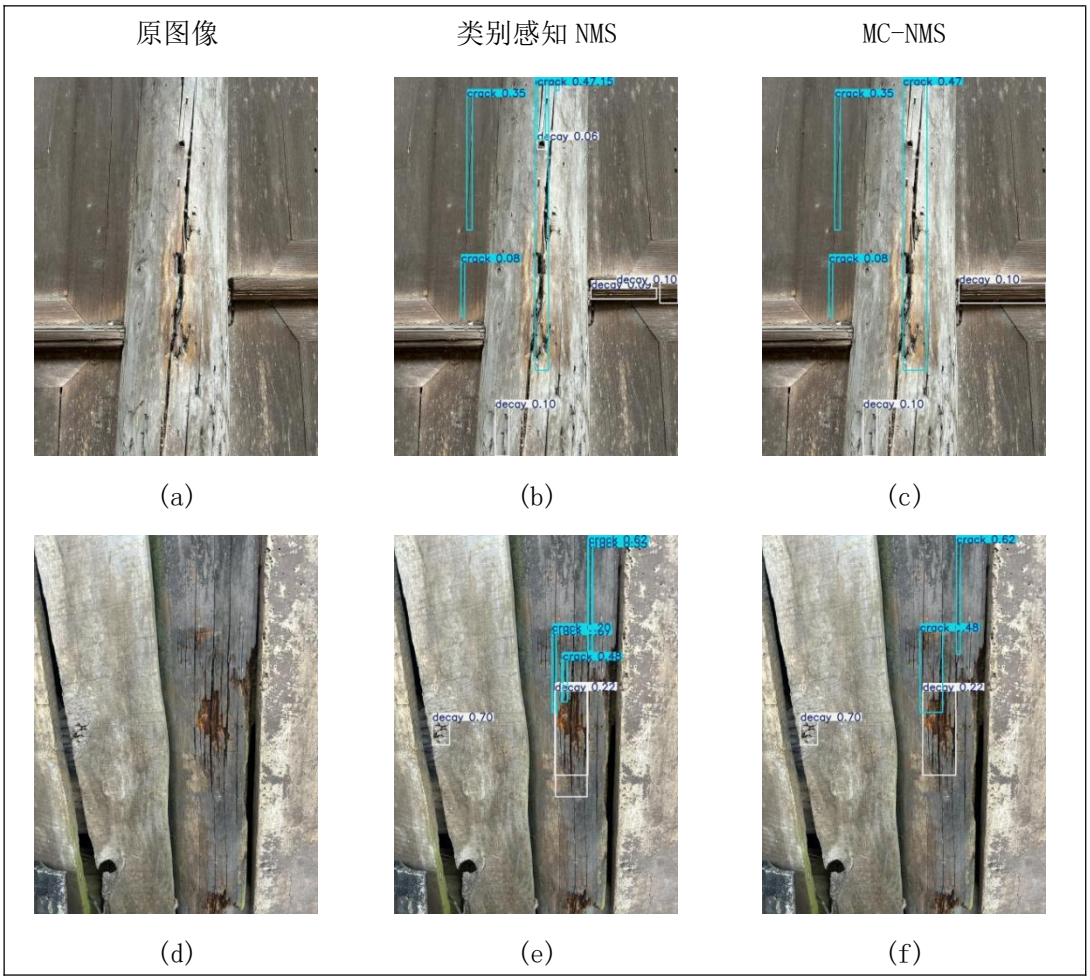


图 17 传统 NMS 与 MC-NMS 的对比

图片来源：笔者自作

本研究进一步验证了改进模型在具体损伤检测任务中的优越性，分析了混合聚类的非极大值抑制（MC-NMS）算法在边缘不明确的腐朽和开裂区域检测中的表现。为了量化改进算法较原始 NMS 的效果提升，本文使用了具有针对性的指标 mAP50、后处理平均耗时（ms）、碎片化指数（FI）和区域覆盖度（RCD）。FI 的含义是同一真实目标被分割且预测为 TP 的预测框数量，RCD 可以用于衡量模型生成的检测框是否足够精确地覆盖了真实的损伤区域，计算方法是统计预测框与真实框 IoU 大于等于某一阈值的数量。实验严格控制了变量，采用了相同的置信度阈值（0.05）、IoU 阈值（0.8）和相同的验证集。验证集包含 21 张图像裂缝样本量为、节子样本量为、腐朽样本量为、虫蛀样本量为。结果如表 5 所示，改进 NMS 在 mAP、FI 和 RCD 三大指标上均得到了优化，特别是 FI 指标降低了 12，说明其能够更好抑制重复检测问题。改进算法在处理时间上较原始 NMS 有一定上升，但考虑到本研究不对模型的实时检测性能做要求，因此增加的耗时在可接受范围。图 17 可视化展示了不同 NMS 在损伤检测任务中的区别，可以

发现在同样的置信度阈值和 IoU 阈值条件下，MC-NMS 更加有效的抑制了损伤重复标记的问题。实验结果显示，MC-NMS 在处理目标边界模糊、损伤形态复杂的检测任务时，能够更有效地整合预测框的信息并输出更接近真实值的结果。这一结果进一步证明了 MC-NMS 在传统建筑木构件损伤检测任务中具有重要的应用价值。

5.3 注意力机制关注区域对比

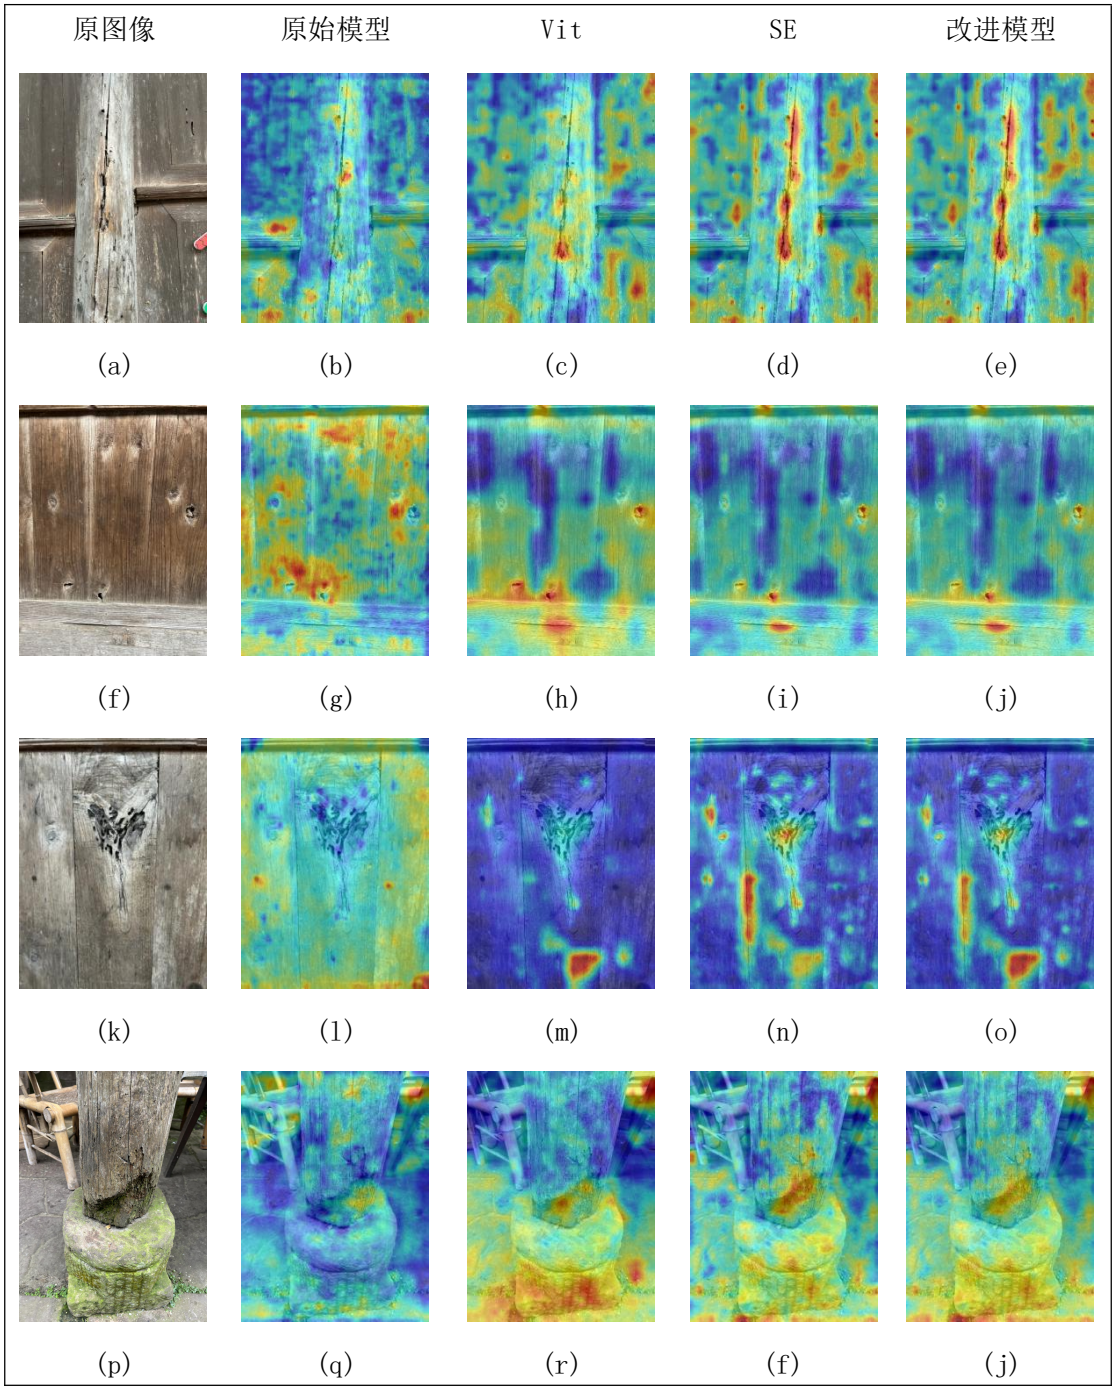


图 18 原始模型关注区域、注意力机制关注区域以及改进模型关注区域

图片来源：笔者自作

本文对比了不同的注意力机制在检测任务中关注区域的区别，试图验证注意力机制对模型关注区域调整的有效性，我们采用的是 Grad-CAM 技术进行可视化分析[48]。针对原始 YOLO v8 模型，我们选择了 Backbone 中的第 6、7、8、9 层以及三个检测头前的特征图集成生成热力图以展示其关注区域。对于仅包含 ViT 模块的模型，我们选取了第 6、7、8、9 层、ViT 模块所在的第 10 层后的特征图以及三个检测头前的特征图生成热力图。针对仅包含 SE 模块的模型，我们选择了第 6、7、8、9 层、三个 SE 模块层后的特征图生成热力图。最后，对于本文提出的改进模型（结合 ViT 和 SE 模块），我们综合选取了第 6、7、8、9 层、ViT 模块层以及 SE 模块层后的特征图生成热力图。图 18 是不同模型关注区域的对比，可以清楚的看到注意力机制提高了模型对损伤区域的关注程度，对复杂背景的抑制效果显著。实验揭示了改进模型在目标检测任务中对关键区域的关注能力提升。

5.4 传统建筑木构件损伤检测系统实践

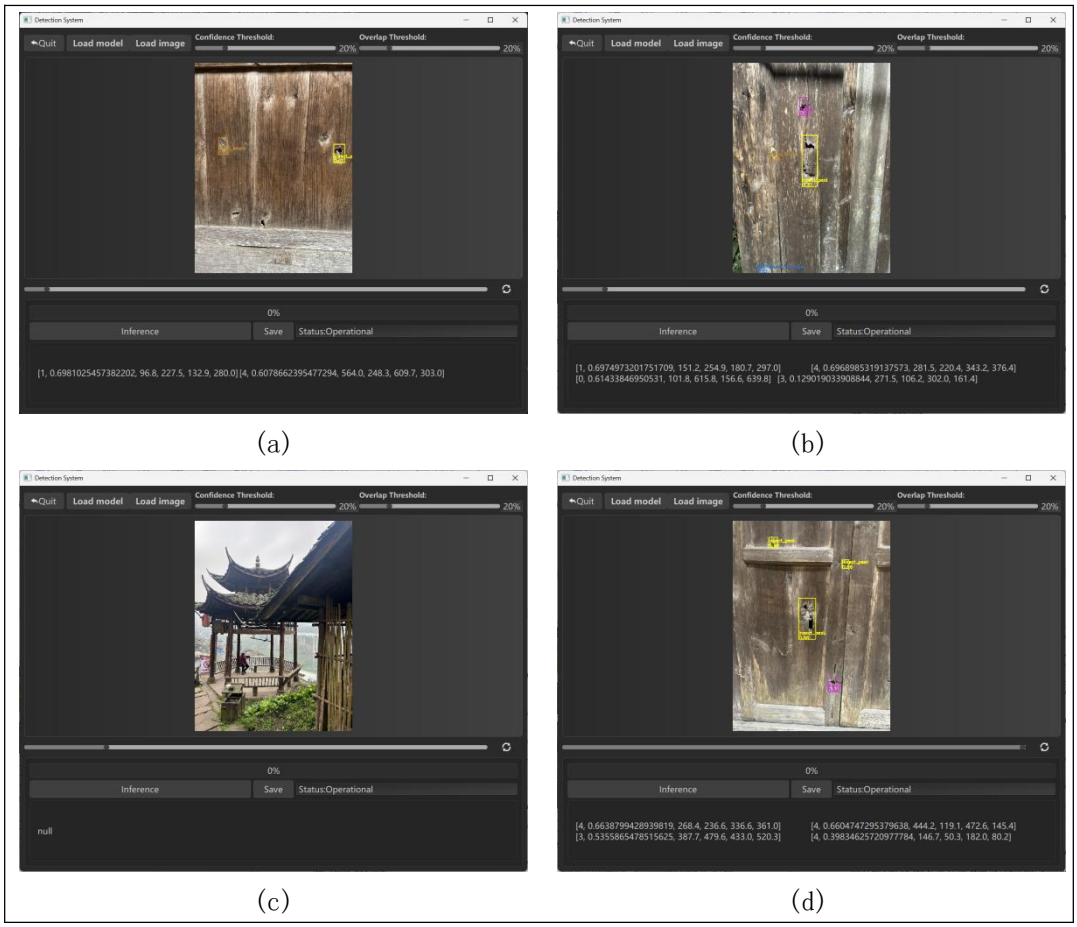


图 19 损伤检测系统图像检测窗口实验

图片来源：笔者自作

表 6 系统检测与人工检测对比实验结果

方法	Precision	检测耗时（s）
人工检测	0.87	711.46
系统检测	0.83	16.52

启动损伤检测系统，在图像检测模块中上传实地拍摄的 24 张图像，并加载改进 YOLO v8 模型的 ONNX 文件。调节滑块设置置信度阈值为 0.2，重叠度阈值为 0.2，点击“推理”按钮开始目标检测。检测完成后，点击切换按钮，在窗口上显示检测结果，部分图片检测结果如图 19 所示。可以看到，损伤被成功的标注，类别、置信度、损伤在图片上的位置信息也被顺利输出。值得一提的是，系统并不会被噪声图片干扰，如图 19 中的 c 图所示对于无效图片系统能够正确判别，并在信息栏输出了空值。为了揭示损伤检测系统的较人工检测的优越性，本研究采用人工标注方法对比验证系统的效率和准确性，由两名受过木构件损伤检测培训的实验员进行目视损伤标注，标注工具为 lableimg。以检测完成所用时间为效率评判标准，以置信度阈值大于 0.2，IoU 阈值大于 0.2 时的 Precision 作为精度评判标准，人工组效率和精度取两名实验员的最优值。

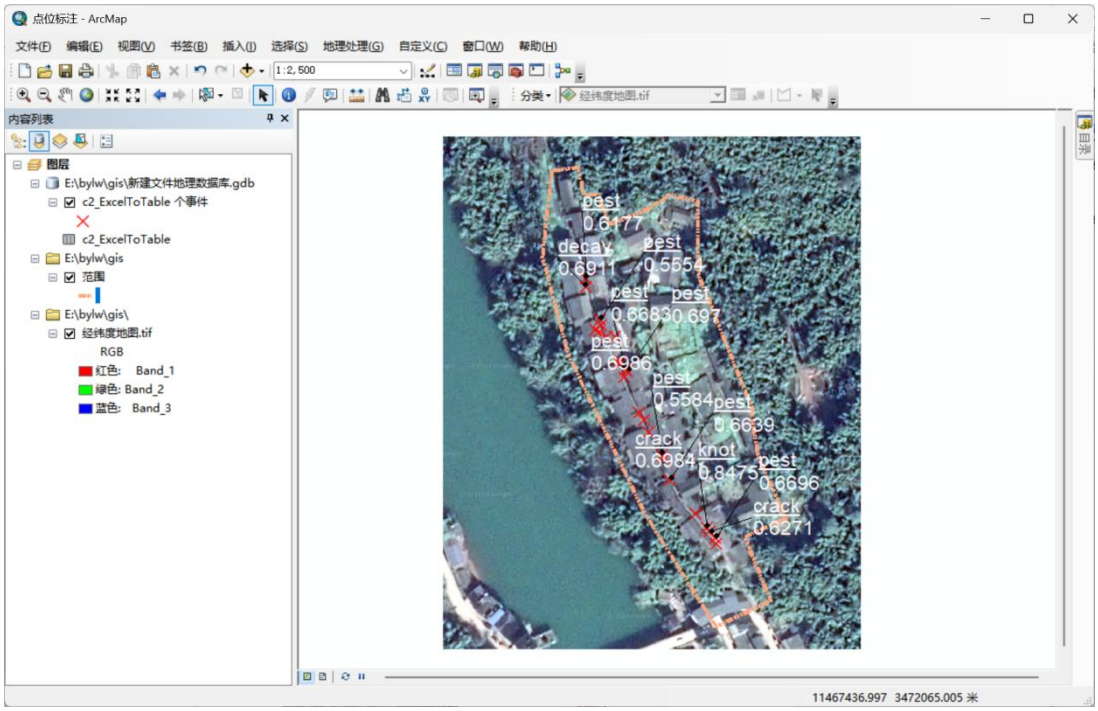


图 20 结合地理信息系统的损伤标注

图片来源：笔者自作

对比结果如表 6 所示，系统检测效率较人工检测提升 43 倍，人工检测精度较系统检测精度高 0.04。实验结果让人兴奋，系统的效率远远高于人工，且精度

较人工差距小，考虑到检测成本，本研究开发的木构件损伤检测系统较传统人工检测更能够适应于实际的检测任务。点击“保存”按钮将结果导出，并将结果表格进一步导入 GIS 系统，转换为 Shape 文件后生成如图 20 所示的损伤点空间分布图，用以直观展示损伤分布与类型，为后期的损伤修复工作，保护规划工作提供了依据。

6.结论

本研究引入了 ViT 和 SE 注意力机制对 YOLO v8m 模型进行优化，使用分阶段冻结与解冻的训练策略，成功训练得到了一个适用于中国西南地区传统建筑木构件损伤检测的模型。训练过程和实验结果证实了改进模型能够有效学习到木构件损伤的特征，并且能够在在复杂背景、小目标和损伤表征差异大的检测任务中较原始模型表现出显著优势，其 mAP50 和 mAP50-95 分别达到了 0.658 和 0.5，比原始模型提升 4%和 3%。本文借助 Grad-CAM 可视化实验呈现了植入注意力机制给模型关注损伤区域带来的影响，MC-NMS 使检测结果的碎片化指数降低了 23.6%，有效改善了重复检测问题。在中国望鱼古镇的实地验证里，系统对 24 组现场图像的检测精度达到 83%，检测速度相比人工提升了 43 倍。后续结合 GIS 生成的损伤空间分布图为传统建筑保护给予了精准的数字化支持，本研究为传统建筑损伤检测提供了新的技术范式，其损伤检测系统的设计思路对类似文化遗产保护研究成果的落地有普适参考价值。

参考文献

[1] R.-y. Yang, Y.-f. Sun, X.-f. Zhang, Application and Progress of Reinforcement Technology for Chinese Ancient Buildings with Wood Structure, Geotechnical and Geological Engineering 38(6) (2020) 5695-5701.

[2] Q. Han, C. Yin, Y.Y. Deng, P.L. Liu, Towards Classification of Architectural Styles of Chinese Traditional Settlements Using Deep Learning: A Dataset, a New Framework, and Its Interpretability, REMOTE SENSING 14(20) (2022).

[3] H.F. Wang, S.C. Chiou, Research on the Sustainable Development of Traditional Dwellings, SUSTAINABILITY 11(19) (2019).

[4] R. Ehtisham, W. Qayyum, C.V. Camp, V. Plevris, J. Mir, Q.-u.Z. Khan, A. Ahmad, Computing the characteristics of defects in wooden structures using image processing and CNN, Automation in Construction 158 (2024).

[5] Z. Xin, Y. Li, X. Qiu, H. Zhang, J. Zhou, J. Yuan, Y. Zong, T. Zhang, Effects of environmental factors on natural aging of timber members of ancient buildings: Ultraviolet radiation, temperature and moisture, Construction and Building Materials 456 (2024).
[6] S. Yang, Y.L. Chen, L. Zheng, J.M. Chen, Y.H. Huang, Y. Huang, N. Wang, Y.X. Hu, Investigating and Identifying the Surface Damage of Traditional Ancient Town Residence Roofs in Western Zhejiang Based on YOLOv8 Technology, COATINGS 15(2) (2025).
[7] M. Ji, W. Zhang, J.-k. Han, H. Miao, X.-l. Diao, G.-f. Wang, A deep learning-based algorithm for online detection of small target defects in large-size sawn timber, Industrial Crops and Products 222 (2024).
[8] A.O. Soge, O.I. Popoola, A.A. Adetoyinbo, Detection of wood decay and cavities in living trees: a review, Canadian Journal of Forest Research 51(7) (2021) 937-947.
[9] H.S. Munawar, A.W.A. Hammad, A. Haddad, C.A.P. Soares, S.T. Waller, Image-Based Crack Detection Methods: A Review, Infrastructures 6(8) (2021).
[10] O. Avci, O. Abdeljaber, S. Kiranyaz, M. Hussein, M. Gabbouj, D.J. Inman, A review of vibration-based damage detection in civil structures: From traditional methods to Machine Learning and Deep Learning applications, MECHANICAL SYSTEMS AND SIGNAL PROCESSING 147 (2021).
[11] N. Kheradmandi, V. Mehranfar, A critical review and comparative study on image segmentation-based techniques for pavement crack detection, CONSTRUCTION AND BUILDING MATERIALS 321 (2022).
[12] X. Zhao, L.M. Wang, Y.F. Zhang, X.M. Han, M. Deveci, M. Parmar, A review of convolutional neural networks in computer vision, ARTIFICIAL INTELLIGENCE REVIEW 57(4) (2024).
[13] L.Y. Chen, S.B. Li, Q. Bai, J. Yang, S.L. Jiang, Y.M. Miao, Review of Image Classification Algorithms Based on Convolutional Neural Networks, REMOTE SENSING 13(22) (2021).
[14] Y.J. Mo, Y. Wu, X.N. Yang, F.L. Liu, Y.J. Liao, Review the state-of-the-art technologies of semantic segmentation based on deep learning, NEUROCOMPUTING 493 (2022) 626-646.
[15] S.K. Pal, A. Pramanik, J. Maiti, P. Mitra, Deep learning in multi-object detection and tracking: state of the art, APPLIED INTELLIGENCE 51(9) (2021) 6400-6429.
[16] M.J. Hallee, R.K. Napolitano, W.F. Reinhart, B. Glisic, Crack Detection in Images of Masonry Using CNNs, SENSORS 21(14) (2021).
[17] Z.C. Liu, X.D. Li, J.H. Li, S. Teng, A New Approach to Automatically Calibrate and Detect Building Cracks, BUILDINGS 12(8) (2022).
[18] Y.B. He, Z.R. Yuan, X.H. Xia, B. Yang, H.T. Wu, W. Fu, W.X. Yao, Local-Global Feature Adaptive Fusion Network for Building Crack Detection, SENSORS 24(21) (2024).
[19] J. Ma, W.D. Yan, G.Q. Liu, S.Y. Xing, S.Q. Niu, T. Wei, Complex Texture Contour Feature Extraction of Cracks in Timber Structures of Ancient Architecture Based on YOLO Algorithm, ADVANCES IN CIVIL ENGINEERING 2022 (2022).
[20] H.C. Qiu, J.H. Zhang, L.C. Zhuo, Q. Xiao, Z.H. Chen, H. Tian, Research on intelligent monitoring technology for roof damage of traditional Chinese residential buildings based on improved YOLOv8: taking ancient villages in southern Fujian as an example, HERITAGE SCIENCE 12(1) (2024).
[21] H.D. Tang, Y.L. Feng, D. Wang, R.G. Zhu, L.W. Wang, S.W. Hao, S. Xu, Application of Object Detection Algorithm for Efficient Damages Identification of the Conservation of Heritage Buildings, ARCHAEOLOGICAL PROSPECTION 31(3) (2024) 233-247.

[22] X.D. Zhu, Q.K. Zhu, Q. Zhang, Y.F. Du, Deep learning-based 3D reconstruction of ancient buildings with surface damage identification and localization, STRUCTURES 73 (2025).
[23] Y. Chen, W.Y. Wu, J.X. Li, Adaptive Attention-Enhanced Yolo for Wall Crack Detection, APPLIED SCIENCES-BASEL 14(17) (2024).
[24] R. Sapkota, D. Ahmed, M. Karkee, Comparing YOLOv8 and Mask R-CNN for instance segmentation in complex orchard environments, ARTIFICIAL INTELLIGENCE IN AGRICULTURE 13 (2024) 84-99.
[25] K.M. He, G. Gkioxari, P. Dollár, R. Girshick, Mask R-CNN, IEEE TRANSACTIONS ON PATTERN ANALYSIS AND MACHINE INTELLIGENCE 42(2) (2020) 386-397.
[26] M. Hussain, YOLO-v1 to YOLO-v8, the Rise of YOLO and Its Complementary Nature toward Digital Manufacturing and Industrial Defect Detection, MACHINES 11(7) (2023).
[27] D. Biswas, H.B. Su, C.Y. Wang, A. Stevanovic, W.M. Wang, An automatic traffic density estimation using Single Shot Detection (SSD) and MobileNet-SSD, PHYSICS AND CHEMISTRY OF THE EARTH 110 (2019) 176-184.
[28] J.L. Tang, S.B. Liu, D.X. Zhao, L.J. Tang, W.H. Zou, B. Zheng, PCB-YOLO: An Improved Detection Algorithm of PCB Surface Defects Based on YOLOv5, SUSTAINABILITY 15(7) (2023).
[29] Z.X. Zhang, Drone-YOLO: An Efficient Neural Network Method for Target Detection in Drone Images, DRONES 7(8) (2023).
[30] X.J. Hao, L. Liu, R.J. Yang, L.Z.Y. Yin, L. Zhang, X.H. Li, A Review of Data Augmentation Methods of Remote Sensing Image Target Recognition, REMOTE SENSING 15(3) (2023).
[31] K. Haciefendioglu, S. Ayas, H.B. Basaga, V. Togan, F. Mostofi, A. Can, Wood construction damage detection and localization using deep convolutional neural network with transfer learning, EUROPEAN JOURNAL OF WOOD AND WOOD PRODUCTS 80(4) (2022) 791-804.
[32] Z. Tian, C.H. Shen, H. Chen, T. He, FCOS: A Simple and Strong Anchor-Free Object Detector, IEEE TRANSACTIONS ON PATTERN ANALYSIS AND MACHINE INTELLIGENCE 44(4) (2022) 1922-1933.
[33] Z. Liu, X.Y. Gu, J.Q. Chen, D.Y. Wang, Y.H. Chen, L.T. Wang, Automatic recognition of pavement cracks from combined GPR B-scan and C-scan images using multiscale feature fusion deep neural networks, AUTOMATION IN CONSTRUCTION 146 (2023).
[34] Y.H. Jiang, S.S. Han, Y. Bai, Development of a Pavement Evaluation Tool Using Aerial Imagery and Deep Learning, JOURNAL OF TRANSPORTATION ENGINEERING PART B-PAVEMENTS 147(3) (2021).
[35] D.H. Ai, G.Y.J. Jiang, S.K. Lam, P.L. He, C.W. Li, Computer vision framework for crack detection of civil infrastructure-A review, ENGINEERING APPLICATIONS OF ARTIFICIAL INTELLIGENCE 117 (2023).
[36] Z.F. Elsharkawy, H. Kasban, M.Y. Abbass, Efficient surface crack segmentation for industrial and civil applications based on an enhanced YOLOv8 model, JOURNAL OF BIG DATA 12(1) (2025).
[37] G.L. Yang, J.X. Wang, Z.L. Nie, H. Yang, S.Y. Yu, A Lightweight YOLOv8 Tomato Detection Algorithm Combining Feature Enhancement and Attention, AGRONOMY-BASEL 13(7) (2023).
[38] A. Vijayakumar, S. Vairavasundaram, YOLO-based Object Detection Models: A Review and its Applications, MULTIMEDIA TOOLS AND APPLICATIONS (2024).
[39] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, An image is worth 16x16 words: Transformers for image recognition at scale, arXiv preprint arXiv:2010.11929 (2020).

[40] J. Hu, L. Shen, G. Sun, Squeeze-and-excitation networks, Proceedings of the IEEE conference on computer vision and pattern recognition, 2018, pp. 7132-7141.
[41] X. Liu, L. Zhang, M. Li, H. Zhang, D. Wang, Boosting image classification with LDA-based feature combination for digital photograph management, Pattern Recognition 38(6) (2005) 887-901.
[42] E.J. Hoffmann, K. Abdulahhad, X.X. Zhu, Using social media images for building function classification, Cities 133 (2023).
[43] K.G. Fendi, S.M. Adam, N. Kokkas, M. Smith, An Approach to Produce a GIS Database for Road Surface Monitoring, APCBEE Procedia 9 (2014) 235-240.
[44] S. Li, Z. Yuan, R. Peng, D. Leybourne, Q. Xue, Y. Li, P. Yang, An effective farmer-centred mobile intelligence solution using lightweight deep learning for integrated wheat pest management, Journal of Industrial Information Integration 42 (2024).
[45] K. Chen, G. Reichard, A. Akanmu, X. Xu, Geo-registering UAV-captured close-range images to GIS-based spatial model for building façade inspections, Automation in Construction 122 (2021).
[46] H.S. Lallie, Dashcam forensic investigation guidelines, Forensic Science International: Digital Investigation 45 (2023).
[47] Y. Cao, Y. Liu, Y.K. Sun, S. Su, F. Wang, Enhancing rail safety through real-time defect detection: A novel lightweight network approach, ACCIDENT ANALYSIS AND PREVENTION 203 (2024).
[48] R.R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, D. Batra, Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization, INTERNATIONAL JOURNAL OF COMPUTER VISION 128(2) (2020) 336-359.

数据可用性声明

本研究承诺应要求提供原始数据与代码。

致谢

作者感谢导师肖海老师对本研究进行了严谨细致的指导，感谢四川省雅安市望鱼镇望鱼村村委会对本研究的支持。