四川农业大学研究生
学位论文开题报告

中文题目：基于深度学习的嘉绒藏族民居木质构件损伤识别研究

英文题目：Research on Damage Identification of Wooden Components in Jiarong Tibetan Dwellings Based on Deep Learning

姓　　名：张绍良

学　　号：2024325033

层　　次：工程硕士

学科专业：土木工程 085901

研究方向：传统建筑数字化保护

培养单位：建筑与城乡规划学院

导　　师：肖海

报告时间：2025 年 12 月

四川农业大学研究生院制表

填 表 说 明

一、总体要求

研究课题应符合学科（方向）或专业学位类别（领域）的培养目标，立题依据充分，研究内容充实，研究方案和进度安排合理，学术学位研究生的研究课题必须具备科学性、学术性、创新性和可行性，专业学位研究生的研究课题应立足本类别或领域，解决实际问题，具有一定应用价值。

二、封面填写说明

1. 学科专业：按学科、专业学位类别（领域）填写学科全称和代码，例如：生物学（071000）、会计（125300）；

2. 研究方向：须咨询导师，原则上应属于本学位点学科培养方向之一。

三、开题报告版式与打印要求如下：

1. 打印要求：A4 幅面，双面打印，一式 2 份（打印前应更新目录域以保持页码正确）。

2. 页面要求：上-3.0 厘米，下-3.0 厘米，左-3.0 厘米，右-3.0 厘米，装订线 0 厘米；页眉距边界：1.5 厘米，页脚距边界：1.75 厘米。

一、选题意义和国内外研究进展

1 课题来源

本选题依中国民族建筑研究会 2025 年度科研课题《人工智能支持下嘉绒藏式民居文化基因识别与传承研究》（项目编号：NAIC202518）。该项目旨在利用人工智能技术对嘉绒藏族民居的建筑文化特征进行数字化解析与保护。针对藏式民居立面纹理丰富、装饰线条复杂的视觉难点，课题组前期已通过实地调研与无人机航拍，构建了包含数千张高分辨率民居影像的嘉绒藏族建筑专用数据集；并基于深度学习技术，成功训练了针对屋顶、窗框、装饰线条等不规则构件的像素级自动分割与分类模型。本学位论文正是立足于该项目已形成的数据底座与构件识别算法框架，进一步聚焦于木质构件的物理健康状态评估。旨在解决文化基因“物质载体”的损伤识别难题，为嘉绒藏族民居的数字化建档与预防性保护提供核心技术支撑。

2 研究背景及意义

2.1 研究背景

2.1.1 丹巴嘉绒藏族民居的历史价值与文化意义

在过去较长时期内，传统村落常被视为濒临消失的“文化孤岛”，保护重心局限于物理层面的抢救性修缮。然而，随着国家战略的演进，传统村落的定位已根本性转变为承载乡村产业振兴与文化自信的综合性资源载体[1]。

近年来，国家层面构建了制度保障与技术赋能并重的保护体系。在制度层面，《中华人民共和国乡村振兴促进法》将村落保护上升为国家意志[2]。2024 年与 2025 年的中央一号文件连续释放信号，强调要学习运用“千村示范、万村整治”经验[3]，在推进乡村全面振兴中处理好“传统与现代”的关系，不仅要保护建筑本体，更要提升整体人居环境，为差异化治理提供了最高政治遵循[4]。在技术层面，中共中央办公厅、国务院办公厅印发的《关于推进实施国家文化数字化战略的意见》及“十四五”规划明确提出，要顺应时代发展，积极运用人工智能、大数据等新技术更新遗产保护方式。2023 年提出的习近平文化思想进一步强调了在传承中解决“符号丢失”与“多样性挖掘”的问题[5]。这表明，利用数字化手段建立科学的记录与预防性保护机制，已成为响应国家文化战略的必然选择。

嘉绒藏族的碉房是嘉绒文化中典型的、具有代表意义的文化载体之一，主要以嘉绒

藏房、经堂、碉楼等具象实物建筑为体现形式。它是在特定的自然环境中，嘉绒藏族居民对环境和资源利用的典范，展示出个体与整体美感并存; 同时也是当地居民在历史发展的长河中，当地的自然、生态环境和生产、生活方式等在物质形态和精神理念上的集中反映。碉楼作为重要的民族文化遗产，具有突出的历史文化价值和保护意义[6]。

从构造逻辑来看，嘉绒藏族民居采用了独特的“石木共生”体系。虽然外观为厚重的片石砌筑，但其核心受力骨架——梁、柱、斗拱、楼板、悬挑厕所及门窗——均为木质构件，主要采用当地优质云杉、冷杉木材并通过榫卯连接。这些构件不仅在物理层面上起着承重与连接的关键作用，还在维持‘石木建造的结构’以及内部空间的文化分类具有重要作用[7]。作为承重、连接与围护的关键载体，木构件的健康状况直接决定了建筑的结构安全。因此，在数字化战略背景下，针对丹巴嘉绒藏族民居木质构件开展智能化的损伤识别与评估，既是保护物质遗产的迫切需求，也是传承民族建筑文化的科学路径。

2.1.2 木质构件损伤对传统民居安全的威胁

木质构件在长期使用过程中，受到环境、生物、机械等多方面因素影响，会产生不同程度的损伤。这些损伤主要包括：腐朽、虫蛀、开裂、变形、节点松动等。调研数据显示，丹巴地区传统民居木质构件存在不同程度损伤的比例高达 86.4%，其中严重损伤(需立即修复)的比重达 28.7%，2019 年至 2022 年间，丹巴县共发生 8 起传统民居局部坍塌事件，均与木质构件严重损伤未被及时发现有关，造成了极大的文化遗产损失和人员安全风险[8]。

木质构件损伤不仅威胁建筑结构安全，也会损害传统民居的文化价值。许多传统民居中的木质构件不仅是结构部件，更是雕刻艺术的载体。梁头、雀替、门窗格心等部位通常绘有精美的图案和纹饰，反映了嘉绒藏族的宗教信仰、生活习俗和审美观念。一旦这些构件因损伤而被更换，原有的历史信息和艺术价值将永久丧失。

2.1.3 传统检测方法的局限性

目前，丹巴嘉绒藏族民居木质构件的损伤检测仍深度依赖人工目视检查和简单工具辅助的传统模式，该方法在实际工程应用中暴露出显著的局限性。首先，检测结果高度依赖人员经验，导致漏检率居高不下，且受限于偏远山区专业设备匮乏，肉眼难以察觉木材内部的隐蔽性虫蛀与腐朽[9]。其次，实施过程面临效率低下、成本高昂与安全风险大的多重挑战。面对全县民居的庞大体量，全面普查不仅耗时长且经济成本巨大，且因传统民居结构老化，检测人员需频繁攀爬高处或进入非稳固区域，极易引发安全事故。最后，检测数据的记录方式过于原始，仅靠文字描述与简单绘图难以精确记录构件损伤

的形态与空间位置信息，导致档案数据的离散化与模糊化，无法为后续的科学修缮与长期监测提供精准的数据支撑。传统监测方法与基于深度学习的监测方法特点见表 1。

表 1：传统监测方法与基于深度学习的监测方法对比

维度	传统人工巡查	物理传感器监测（IoT）	基于深度学习的视觉监测
覆盖范围	抽样点，存在盲区	单点监测，覆盖面有限	面域全覆盖，无死角
检测精度	依赖主观经验，定性为主	极高(微米级)，定量	高(亚毫米级)，定量与定性结合
实施成本	人力成本高，交通成本高	设备及布线成本极高	硬件成本低(无人机/相机)，算法复用成本低
对建筑影响	需搭建脚手架，可能有接触	需安装设备，有接触风险	完全非接触，最安全
数据形态	纸质/文本报告，难以检索	线性时间序列数据	结构化图像数据+空间分布模型
适用场景	小规模、低层建筑	重点保护的单体孤例	大规模、分布广的传统村落群

2.1.4 现有深度学习技术应用在传统建筑保护的不足

尽管深度学习在通用目标检测领域已取得显著成果，但将其直接应用于嘉绒藏族民居这类具有特殊构造与复杂纹理的传统乡土建筑保护时，仍存在明显的适用性缺陷与技术短板：

（1）缺乏针对特定地域建筑特征的专用数据集。深度学习算法的性能高度依赖于训练数据的规模与质量。目前，公开的建筑病害数据集多集中于现代混凝土裂缝或实验室环境下的木材缺陷，极度缺乏针对藏式传统建筑的专用图像数据。现有的数据集无法涵盖丹巴地区特有的彩绘装饰、烟熏积炭以及高原强光照等复杂场景特征。这导致直接使用通用数据集训练的模型在面对嘉绒民居时泛化能力严重不足，无法有效适配其独特的地域性特征，难以对各类特殊的损伤形态进行精准识别。

（2）通用模型难以应对强背景干扰下的特征混淆。现有的主流检测模型多是为自然图像设计的，其特征提取机制更倾向于捕捉显著的轮廓信息。然而，嘉绒藏族民居木构件表面密布高频的装饰彩绘与雕刻纹样，这些人工线条在形状和颜色上与真实的裂缝、虫眼高度相似。通用模型缺乏针对性的抗干扰设计，在处理此类高噪图像时，往往无法区分，导致极高的误检率，难以满足古建筑保护对高精度的要求。

（3）缺乏工程化的量化评估能力。目前的深度学习应用研究多停留在“视觉识别”层面，即仅仅在图像中识别损伤的大致位置，而缺乏对损伤程度的量化分析能力，实用

价值非常有限，未能打通从图像检测到工程指标的转化路径，难以直接输出符合文物保护规范的评估等级，导致识别结果无法直接指导现场的修缮决策，存在技术与应用脱节的现象。

2. 2 研究意义

2.2.1 理论意义

（1）填补嘉绒藏族建筑病害研究缺口，完善藏族民居保护理论体系。嘉绒藏族民居作为川西高原的建筑瑰宝，其独特的“石木共生”结构在建筑史上具有重要地位。但长期以来，关于其木质构件的病害研究多停留在文字描述层面，缺乏系统的图像数据和量化分析。本研究通过对典型民居木质构件损伤特征的深度挖掘与分类研究，厘清在高原特殊环境下木材的“病理特征”，丰富了嘉绒藏族民居作病害理论资料，为后续的保护理论研究提供了翔实的实证依据。

（2）拓展人工智能技术在乡土传统建筑保护中的应用范畴。既往的计算机视觉技术多应用于现代城市建筑或工业检测，针对具有复杂彩绘、烟熏痕迹和非标准形态藏族传统建筑的研究相对滞后。本研究尝试将深度学习技术引入这一特定领域，探索在强干扰背景下提取微弱损伤特征的可行性，证明现代智能技术同样适用于传统乡土传统建筑的保护，为科技赋能传统建筑保护提供了新的研究视角和方法论证。

（3）揭示“环境-构造-损伤”的关联规律，深化对建筑老化机理的认知。本研究不仅仅是识别裂缝，更试图通过数据统计，分析损伤在不同建筑部位（如承重梁柱与装饰门窗）以及不同微环境下的分布差异。这种从“表象识别”到“规律探究”的理论尝试，有助于更深层次地理解嘉绒藏族民居在自然环境作用下的老化演变规律，为预防性保护理论的构建提供了数据支撑。

2.2.2 现实意义

（1）实现修缮决策的精准化。本研究建立的智能识别方法，可以改变过去仅凭工匠肉眼经验进行定性判断的传统模式。通过深度学习算法对木质建筑构件损伤进行精确的定位和损伤程度计算，如裂缝长度、腐朽占比。可以为相关保护部门提供客观的体检报告，有助于制定差异化的干预策略——对严重损伤进行结构加固，对轻微损伤进行表面保养，从而有效避免修缮过度或保护不足。

（2）解决高危盲区检测难题，提升巡检工作的安全性和效率。丹巴碉楼建筑高度大且地势险峻，传统人工攀爬检测不仅效率低，且存在极大的安全隐患。本研究构建的

计算机视觉检测模型，配合无人机等设备，可以实现非接触式的检测与诊断，能覆盖檐下、悬挑梁等人工视线检测盲区。这为大规模传统村落的健康体检提供了一种高效、安全、低成本的新手段，极大地降低了工作难度。

（3）构建木构件损伤数字化档案，帮助传统村落的长期监测、保护与传承。利用本研究的技术，可以为每一栋嘉绒藏族民居建立专属的“病害数字档案”。这些经过数字化处理的影像和数据，不仅记录了建筑当下的健康状况，也可用于后续的长期监测和对比分析；同时也高保真地留存了珍贵的营造技艺信息，防止因构件腐朽消失而导致文化信息的丢失，对于该地区藏族文化的数字化抢救与传承具有重要的现实价值。

3 国内外研究现状

3.1 基于传统数字图像处理的结构表面损伤识别研究

早期的结构健康监测主要依赖人工近距离的接触式测量，如 1995 年钟明全[10]在混凝土梁疲劳试验中采用放大镜进行裂缝人工读数，以及聂建国等[11]使用接触式千分表测量裂缝宽度，这些方法虽然在实验室环境下能获得一定精度，但在面对大型工程或高耸建筑时存在效率低下、主观性强及安全隐患等显著局限。随着计算机视觉技术的介入，基于数字图像处理（DIP）的非接触式检测逐步成为研究热点，其核心流程通常遵循“预处理—特征提取—量化”的线性范式。在特征提取算法方面，张海明[12]经过对比分析提出 Sobel 算子在混凝土裂缝提取中表现最佳。严盛龙等[13]创新性地提出了基于亚像素精度的测量方法，利用高斯曲线拟合裂缝边缘，显著提升了宽度计算精度。而李伟等[14]针对立木树干的研究表明 Canny 算子平均误差最小，但也指出梯度算子对环境噪声极为敏感。在精细化量化方面，为突破像素分辨率的限制，周颖等[15]结合形态学处理与像素标定，将裂缝测量误差成功控制在 0.1mm 左右。为了解决复杂背景下的分割难题，房铭坤等[16]与韩豫等[17]采用 Ostu 算法（最大类间方差法）结合形态学处理实现了裂缝的自动阈值分割。正如车紫进[18]所指出，为了应对复杂裂缝往往需要组合多种繁琐的图像处理步骤，当面对嘉绒藏族民居这类具有强光照阴影、烟熏积炭及木材天然纹理的非结构化环境时，传统算法极易因特征混淆而失效。杨才千等[19]则提出了自适应阈值法以应对蜂窝麻面背景的干扰。然而，传统 DIP 方法本质上依赖人工设计的浅层特征，鲁棒性较差。

3.2 基于深度学习的智能识别技术发展现状

近年来，深度学习凭借其强大的特征自学习能力，彻底改变了土木工程领域的检测

范式，依据识别任务的精细度，现有研究已形成了从“图像分类”到“目标检测”再到“语义分割”的完整技术体系。

在图像级分类与目标检测方面，深度学习主要解决损伤的“有无”与“定位”问题。3Hatır M E，Dais D 等人验证了深度学习模型在处理具有复杂纹理背景（石材、砌体）的结构表面损伤特征提取方面的有效性[20]，为木材表面检测提供了技术路线参考[21]。王睿等[22]证实了特征的有效选取可显著提高识别精度，王丽萍等[23]通过改进 AlexNet 网络使路面裂缝识别准确率达到了 98.5%。针对多目标分类任务，褚鸿鹄[24]基于 FPN 架构改进 Faster R-CNN，实现了对龟裂、横纵裂缝的精准分类，其中龟裂检出精度高达 100%。骆剑彬等[25]针对水下桩墩表观裂缝、凹坑及空洞等病害,提出基于深度学习的智能检测,使用声呐对表观病害进行处理获取图像并建立数据集;其次,改进 VGG16 模型用于模型训练并确定评价指标;最终,结果表明模型对各类病害的识别准确率和平均 F1 值高达 88.3%和 87%,证实该法的可行性和有效性。Dimitris Dais 等[26]针对砌体结构的表观裂缝,提出深度学习模型检测,建立了包含不同种类裂缝的数据集,结果表明模型的识别精度和 F1 分数值可达 95.3%和 79.6%,首次实现砌体表观裂缝的智能识别。为了满足实时性需求，温作林[27]研究发现 YOLOv3 在保持 95.9%准确率的同时检测速度远优于 VGG16 等分类网络，张兴成[28]基于 SSD 网络实现了混凝土裂缝的实时检测。此外，Song Ee Park 等[29]尝试将 YOLO 算法与激光传感器结合，通过视觉定位辅助激光测距，探索了视觉和物理测量的复合路径。

在像素级语义分割与量化方面，深度学习正朝着更高精度与更强抗干扰能力方向发展。翁飘[30]、沈俊凯[31]及陈波等[32]利用改进 FCN 模型实现了路面和坝面裂缝的像素级分割，部分研究的后期量化误差已低至 5%。随着 U-Net 架构的普及，朱苏雅等[33]与任秋兵等[34]基于该网络实现了桥梁及水工混凝土裂缝的精确分割，其中朱苏雅的研究将裂缝宽度测量误差控制在 0.05mm 以内。针对复杂背景干扰这一核心痛点，徐国整等[35]与潘刚等[36]在网络中创新性地嵌入了注意力机制，强迫模型关注损伤特征区域，显著提升了模型在干扰环境下的分割精度。Bubryur Kim 等[37]为解决人眼识别钢框架损伤费时费力且误差大的问题,针对损伤图像,提出深度卷积神经网络方法进行分类识别。建立 114 组的训练和验证数据集,结果表明准确率高达 99.3%,证实提出算法的有效性和可行性。但上述方法仅能提供矩形检测框，无法获取损伤的精确几何边缘，难以满足精细化评估的需求。

值得注意的是，代洋洋[38]针对视网膜微血管提出的 UU-Net 模型，通过融合残差模块与注意力机制解决了细微线性目标的断连问题，这为本研究中微小木材裂缝的识别提供了重要的跨学科技术参考。

3.3 古建筑木结构损伤检测的进展

相比于混凝土与路面工程领域成熟的智能化应用，古建筑木结构的损伤检测研究具有特殊性，目前主要集中在内部探伤与初步的视觉识别阶段，技术手段更新相对滞后。Ma 等人[39]对比了 YOLO v3、YOLO v4 和 YOLO v5 在检测古代建筑木结构裂缝任务中的效果，首次将 YOLO 模型应用于古建筑木结构裂缝检测领域。随后目标检测技术被更多的学者用于建筑损伤检测中，Qiu 等人[40]使用 YOLO v8 检测屋顶上可能存在的缺陷，创新点在于提出了一种在大型历史街区或传统村落的背景下快速识别和检测历史建筑遗产疾病的方法。

在内部缺陷检测方面，现有研究多依赖仪器进行物理探测。戴俭[41]通过建立应力波波速与空洞面积的线性模型实现了内部缺陷的量化，而张晓芳[42]、黄荣凤等[43]及李鑫[44]围绕微钻阻力仪开展了大量实验，系统揭示了阻力值与木材密度、腐朽程度及力学性能的定量映射关系。这些方法虽然精度较高，但属于接触式甚至微损检测，操作复杂且效率低下，难以满足大规模传统村落的快速普查需求。

在表观损伤的视觉识别方面，相关探索起步较晚且多停留在初级阶段。黄英来等[45]虽尝试用 FCN 分割活立木图像，但在古建筑领域，王念念[46]建立的基于 CNN 的木构件裂缝与木节模型仍仅限于“图像分类”。马健[47]率先将 YOLO 目标检测算法应用于古建筑木结构，在自建数据集上实现了 91%的裂缝检出率，有效解决了传统人工巡检看不全的问题。杨娜等[48]虽提出了基于无人机和自适应阈值的长期监测系统，但仍未摆脱传统图像处理的局限[49]。Nasir V 明确了 AE 技术在捕捉木材内部活跃缺陷（如正在扩展的裂缝、活动中的虫蛀）释放的瞬态弹性波方面的独特优势[50]。Zhao K 指出了实验室环境下的成像技术应用于复杂现场环境所面临的实际挑战，强调了开发适应原位检测技术的重要性[51]。Zhang L 提出了基于深度学习的方法，专注于中国古代木构件裂缝的识别，并进一步实现了裂缝的量化[52]。Hatır 将研究推进到古建木作这一特定领域，并从单纯的“定性识别”提升到了具有工程价值的“定量评估”（如计算裂缝宽度、长度）[53]。Qian X 等针对传统藏木结构，提出了一种结合变分自编码器（VAE）、多头注意力机制和 LSTM 的复合深度学习模型用于异常检测。开始关注藏式木结构这一特定对象的特

殊性，并引入了先进的注意力机制来处理复杂的结构响应数据[54]。后者以 YOLO 系列[55]以及 SSD[56]为代表，借助一个模型直接完成定位和类别判断任务，检测效率有了较大提升，只是准确率稍有降低，当然当下已有诸多研究尝试借助改进模型架构[57]以及提高数据多样性[58]来提高损伤检测的精度与效率[59]。然而当前研究仍然存在三方面的局限：目前的研究仅顾及了裂缝这类损伤的检测，对于虫蛀、腐朽等同样对结构安全构成威胁的损伤类型关注不够，致使现有的算法泛化能力受到限制。

整体而言，目前鲜有学者针对古建木构件实现基于深度学习的像素级语义分割，无法像混凝土领域那样精确输出裂缝长度、面积占比等关键工程指标，导致识别结果难以直接支撑后续的修缮工程决策。

3.4 研究现状总结与不足

综上所述，国内外在结构损伤识别领域已构建了较为完备的技术体系，尤其是深度学习在混凝土与路面病害检测中已趋于成熟。然而，针对嘉绒藏族民居这一特定对象的深度学习研究仍存在显著空白，主要体现在三个方面：

（1）对象特异性数据的缺失，现有数据集多集中于工业木材或混凝土表面研究对象与专用数据集双重缺失，缺乏针对嘉绒藏族高海拔石砌碉楼与民居这一特定研究对象的深入探索。现有的公开数据集无法覆盖嘉绒藏式民居特有的复杂立面纹理、彩绘装饰以及强光照、深阴影等环境特征。缺乏批量化、真实场景下的高分辨率木质构件损伤影像数据，导致深度学习模型在训练与验证阶段面临数据缺失的困境，难以训练出具有高泛化能力的模型。

（2）复杂背景下的算法适应性不足：算法抗干扰能力的不足，现有通用模型（如标准 YOLO 或 U-Net）未针对藏式民居复杂的结构与装饰混合特征进行优化。在处理具有复杂背景干扰的图像时，现有算法难以准确剥离背景噪声，例如导致细微裂缝与早期腐朽的分割精度较低，无法满足精细化需求。

（3）损伤量化与科学评估体系的断层：大多数古建筑损伤视觉研究止步于“目标检测”，缺乏适用于当地建筑材料的量化算法与分级评估标准，现有的深度学习视觉算法难以直接输出如裂缝最大宽度、腐朽区域密度等工程所需的关键指标，且缺乏将视觉特征转化为修复优先级的科学决策标准，未能实现从像素分割到工程指标的转化链路，导致检测结果难以直接指导后续的修缮工作。

因此，本研究迫切需要构建适巴嘉绒藏族地域建筑保护的技术体系。本文将立足于

嘉绒藏式民居的本体特征，构建带有地域适应性的“图像采集—智能识别—量化评估—辅助决策”闭环技术方法。重点在复杂背景干扰下的构件精准识别与损伤分割，并建立损伤量化评估模型，为民族建筑遗产的预防性保护提供坚实的科学依据。

二、研究目标、研究内容、创新点和拟解决的关键科学问题

1 研究目标

本研究针对嘉绒藏族民居木质构件在复杂背景干扰与独特建筑纹理下的损伤识别难题，构建“图像数据—智能算法—量化评估—工程应用”的完整智能检测与评估体系。研究目标如下：

（1）通过实地采集与历史资料整合，建立首个涵盖多构件类型、多损伤类别的嘉绒藏族民居木质构件损伤高质量数据集，并通过数据增强技术扩充样本至 10000 张以上，为深度学习算法提供坚实的数据支撑。

（2）针对藏式民居特有的彩绘装饰干扰及高海拔多变光照条件，构建融合深度学习算法的模型，提高复杂背景下微小损伤特征提取的准确性，实现损伤识别准及像素级分割的高精度检测目标。

（3）构建基于深度学习计算机视觉的损伤量化评估体系，通过精确提取裂缝几何参数与腐朽区域密度等，建立损伤严重程度与结构安全性的映射模型，为科学修缮提供量化依据。

2 研究内容

2.1 研究对象选取和界定

研究区域位于中国四川省西部的甘孜藏族自治州大渡河流域，该区域不仅是横断山脉高山峡谷区的核心地带，也是藏彝走廊文化交融的关键节点。大渡河发源于青海，于丹巴县城接纳小金川后始称大渡河，随后经泸定县向东注入岷江，在甘孜州境内流长约 242.6 千米。

鉴于大渡河流域地形地貌与人文环境的内部空间异质性，本研究采取了广泛调查加核心村落筛选的采样策略，最终确立丹巴县嘉绒藏族民居为核心研究对象与数据集采集源。通过高分辨率遥感影像初筛并结合县志资料考证，本人初步选取了流域内具有代表性的 12 个传统村落进行实地走访（见表 2），空间范围覆盖了大渡河上游的丹巴县、康

定市以及中下游的泸定县。

表 2 大渡河流域前期调研村落名录

区县	村落名称	平均海拔	民族构成	级别
丹巴县	宋达村	2500 米	藏	第四批国家级传统村落
	莫洛村	2000 米	藏	第一批国家级传统村落
	左边村	1500 米	藏	省级传统村落
	若吉村	1520 米	藏汉	省级传统村落
康定市	前溪村	2300 米	藏	无
	抗州村	1620 米	藏汉	无
	初咱村	2000 米	藏汉	无
	日央村	2200 米	藏	第六批国家级传统村落
泸定县	和平村	1500 米	藏汉彝	无
	咱地村	1800 米	藏汉彝羌	无
	扯蓑坝村	1310 米	藏汉	无
	化林村	2100 米	藏汉	第六批国家级传统村落
	磨子沟村	1500 米	藏汉	无
	磨西镇	1580 米	藏汉彝	无

尽管前期预调研大渡河流域三个行政区划，但本研究把丹巴县嘉绒藏族民居作为核心研究对象主要基于以下三方面的科学考量：

（1）建筑形制的典型性与原真性：相比于下游泸定县等地受汉文化影响较深、现代材料（砖混）介入较多的现状，位于上游的丹巴县被誉为“嘉绒藏族文化的活化石”。该区域完整保留了最为纯粹的“石木共生”建筑技艺，其碉楼与寨房的结合形式在整个大渡河流域最具代表性。这种高纯度的建筑样本能够排除异质文化的干扰，确保研究对象在构造逻辑上的一致性。

（2）木质构件的高占比与病害多样性：丹巴民居保留了全流域最高比例的木质构件使用率（占比超 40%）。由于丹巴地处高山峡谷的迎风坡与阳坡，木构件长期遭受强烈紫外线辐射与河谷风场交替侵蚀，呈现出裂缝、腐朽、虫蛀、变形等最为齐全的病害类型。这种丰富的病害样本对于构建高鲁棒性的深度学习数据集至关重要。

（3）深度学习训练的数据一致性要求：深度学习模型的训练效果高度依赖于数据

分布的一致性。泸定、康定部分村落的民居已出现不同程度的现代风貌改造，若将其混入数据集，会引入大量“非典型”特征噪声，影响模型的收敛精度。因此，聚焦于丹巴这一核心区域，能够保证训练数据的特征分布相对集中，从而训练出针对嘉绒藏族民居具有更高泛化能力的专用识别模型。

利用 ArcGIS 平台绘制了研究区域区位图（如图 1 所示）。

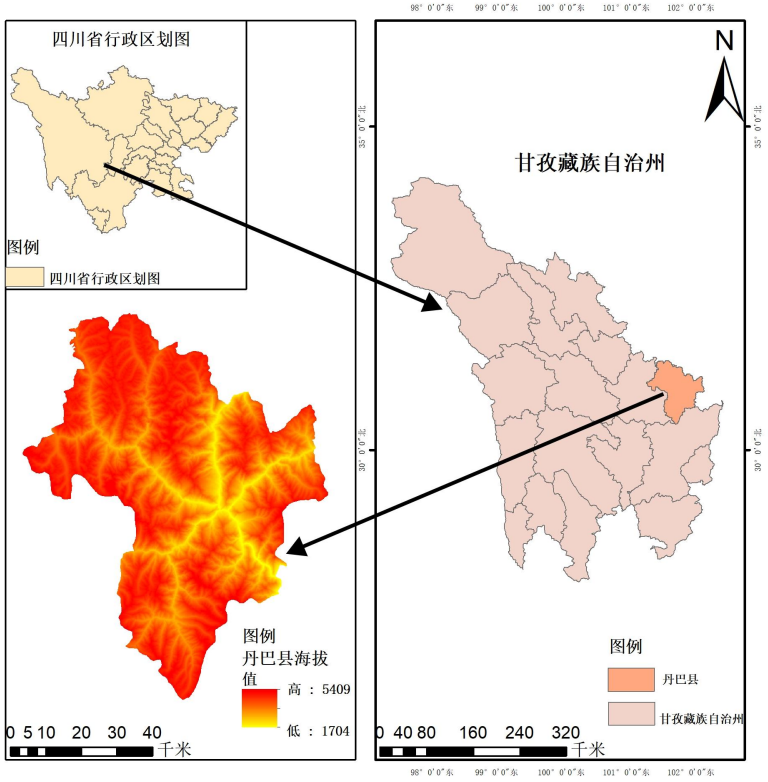


图 1 研究村落区位与高程分析图（来源：作者自绘）

可以看到，丹巴县域内地势落差极大，这种极其悬殊的垂直高差造就了立体气候特征，导致区域内微环境复杂多变。强烈的紫外线辐射、显著的昼夜温差，共同构成了木质构件老化的外部环境诱因。此外，受干热河谷气候影响，木材湿胀干缩频繁，导致该地区木构件普遍存在细微的干缩裂缝。这些裂缝宽度极小（往往小于 2mm），对高分辨率成像设备和算法的微小目标检测能力提出了极高要求。

丹巴县地处大金川河与大渡河交汇的典型河谷地带，是嘉绒藏族文化的核心分布区。该流域以嘉绒藏族聚居为主，融合了羌族、彝族等 24 个民族的文化特质，孕育了独特的语言、宗教与民俗风情。这种多重文化与特殊自然环境的叠加效应，直接催生了该地区极具地域适应性的村落形态与建筑营造技艺。当地居民在长期的生产生活实践中，掌握了精湛的片石砌筑与木构架营造工艺，形成了“石木共生”的独特建筑形式，

且多顺应陡峭山势而建，与其民居建筑共同构成了川西北高原独有的建筑文化景观（见图 2）。



图 2 丹巴县嘉绒藏族民居

（作者自摄）

丹巴嘉绒藏族民居作为川西高原极具地域特色的建筑形式，以其宏大的碉楼与寨房组合而闻名。其建筑主体通常采用当地片石砌筑而成，外观呈现出坚固、厚重的防御性特征，承载了丰富的历史文化信息见（图 3）。





图 3 寨房与碉楼

在传统建筑体系中，木结构与木构件构成了“整体系统”与“个体单元”的有机依存关系。木结构是指由梁、柱、檩、枋等木质构件通过榫卯连接等方式组合而成的受力骨架体系，承担荷载并将其传递至基础，决定了建筑的整体稳定性与抗震性能。木构件作为组成这一系统的基本单元，依据其在建筑中的功能属性，可严格划分为结构承重构件与围护装饰构件两大类。前者如柱、梁、枋等，直接关乎建筑的力学安全，一旦受损

可能引发结构性坍塌；后者如门窗、栏杆、挑廊等，虽然主要承担围护、采光及审美功能，但在嘉绒藏族民居这种特殊的“石木共生”体系中，它们往往不仅仅是纯粹的装饰品。例如，藏式民居厚重的窗框（由层叠的木枋构成）不仅具有极高的民俗审美价值，往往还与墙体拉结，起到一定的辅助稳定作用。因此，在评估体系中，木构件既是承载力学荷载的物理实体，又是承载民族文化符号（彩绘、雕刻）的艺术载体，其健康状态直接决定了传统村落的物理寿命与文化完整性。木构件普遍存在不同程度的材料劣化与结构损伤，这些关键部位的木材纹理、几何形态与表面特征，构成了本研究视觉识别的主要感兴趣区域（见图 4）。





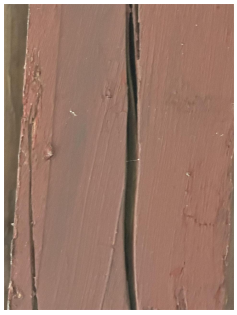
图 4 木质构件支撑体系

木结构损伤（亦称病害）主要涵盖结构体系变形与单体构件材质劣化两个层面。其中，木构件缺陷特指由环境风化、虫蛀侵蚀及生物降解导致的材质败坏。基于物理形态与检测可达性，木构件缺陷通常被划分为内部隐蔽缺陷与外部表观缺陷”两类，前者如内部腐朽与空洞，往往需借助微钻阻力仪或应力波等接触式设备方能探明；后者则直接表现为裂缝、表面腐朽、虫眼及机械损伤等肉眼可见的形态。尽管内部缺陷对结构安全构成潜在威胁，但表观缺陷往往是木材内部病害演化的先兆与必经阶段——例如，表面纵向裂缝的扩展往往诱发内部深层腐烂，而表面虫眼的密集分布则直接预示着内部材质的空洞化。

因此，对木构件表观缺陷的早期识别与量化评估，是实现古建筑预防性保护的第一道防线。然而，针对丹巴嘉绒藏族民居这类具有高耸形制与复杂表面装饰（如彩绘、雕刻）的建筑对象，传统的人工目视检测不仅面临高空作业的安全风险，且极易受光照阴影与人工纹理的干扰，导致漏检或误判。

鉴于此，本研究聚焦于木构件表观缺陷的非接触式智能识别，旨在利用计算机视觉技术克服人眼检测的局限性，实现对表面损伤的高效筛查与精准量化，为评估构件健康状态提供关键的表层数据支撑。主要损伤类型、特征及其形成机理、高发部位如表 3 所示。

表 3 丹巴嘉绒藏族民居木质构件典型损伤形成机理及特征调查表

损伤名称	视觉表征	形成机理	常见高发部位	图示
裂缝(Crack)	表现为木材表面或端面的纵向、斜向及放射状裂隙。裂缝边缘常因长期氧化呈深褐色，内部可见浅黄色木质，具有明显的线性几何特征。	主要源于木材水分流失导致的干缩不均，当内部拉应力超过木材纹理间的结合力时引发开裂；外部荷载作用及剧烈的温差变化会进一步加剧裂纹扩展。	梁、檩条、柱头、柱脚等承重构件	
木节(Knot)	表面颜色通常较周边正常木质更深，呈现圆形、椭圆形或不规则的深褐色斑块，纹理走向与周围木纹不连续。	树木生长过程中枝条与主干的生理性交织遗留（活节），或因病虫害、外力导致的局部组织坏死包裹（死节）。	梁、柱子、木板墙面	
虫蛀(Insect Attack)	表面分布孔状虫眼（圆形或椭圆形），内部存在不规则蛀蚀通道，孔口常堆积有细微木屑或粉末。	白蚁、粉蠹等昆虫在木材内部产卵繁殖，幼虫以啃食木材纤维为生，形成内部空洞网络，严重破坏木材的完整性。	榫卯节点、望板、椽子背面及主要承重梁柱	

在现场调研与数据采集阶段发现，腐朽类病害在丹巴嘉绒藏族民居现存木构件中出现频率极低，经查阅资料和分析，主要因素是丹巴地区典型的干热河谷气候导致空气湿度较低，且木材含水率长期维持在低位，抑制了木腐菌的滋生环境。因此本研究将嘉绒

藏族民居木质构件的主要损伤类型归纳为裂缝、木节与虫蛀三类

2.2 嘉绒藏族民居木质构件损伤数据集构建

图像的质量直接影响到深度学习模型的训练及测试精度，针对现有公开数据集普遍缺乏藏式建筑特征的现状，构建了首个面向嘉绒藏族民居的高质量木质构件损伤数据集 JTTD（Jiarong Tibetan Timber Damage Dataset），以此开展基于深度学习的木构件表观损伤检测研究。

使用智能手机拍摄大量的木构件裂缝图片，为保证损伤图像的多样性，对不同构件如木梁、木柱及斗栱等，在不同光照、不同角度等条件下进行采集。在拍摄过程中应遵循图像不模糊，损伤情况清晰可见且尽可能在图像中部。采集的木构件图像以 JPG 格式存储在计算机硬盘中，为数据集的建立提供样本。现场拍摄图像如图 3.7 所示。



图 5 嘉绒藏族民居图像采集

（作者自摄）

本研究选取丹巴县甲居、梭坡等典型藏寨作为核心采集区，使用无人机近距离摄影与手持设备近距离拍摄相结合的多源互补采集策略。其中，室外利用无人机的高机动性，获取高处屋檐、斗拱及悬挑构件的高分辨率影像；室内场景则通过手持设备克服空间狭窄限制，重点采集暗光环境及彩绘装饰背景下的梁柱及其节点图像，确保了数据的全面性。在此基础上，依托 Roboflow、LabelMe 等平台进行标注，聚焦于裂缝、木结及虫害三种最具代表性的表面特征。最后，为解决样本分布不均可能引发的模型过拟合问题并提升算法泛化能力，本研究实施了基于几何变换的数据增强策略，通过对原始标注图像执行随机旋转、水平与垂直翻转、随机裁剪及多尺度缩放等操作，模拟多样化的拍摄视角与构图模式，在保持图像语义一致性的前提下有效扩充了数据集的规模与多样性，具

体流程如图 6 所示。

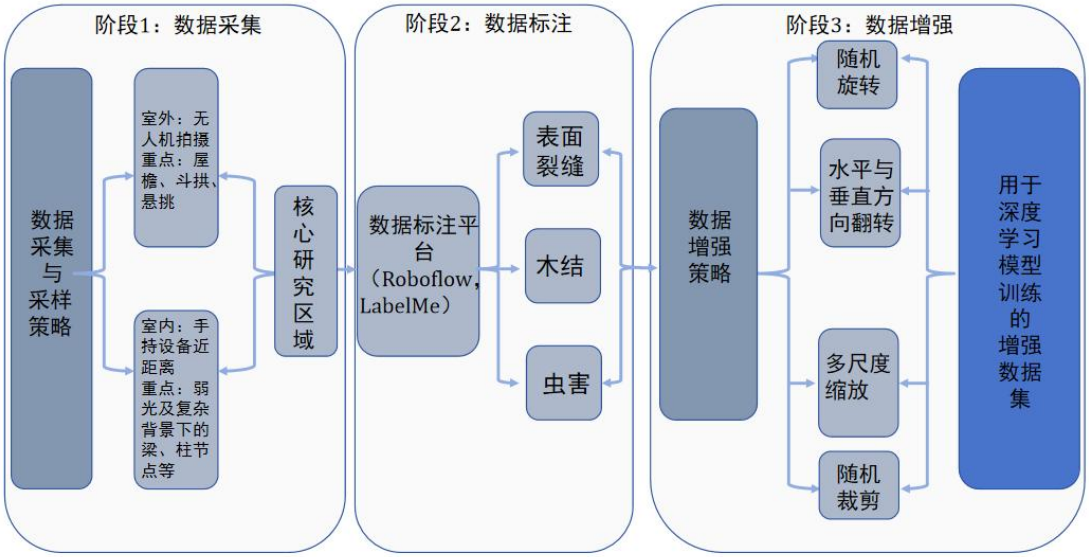


图 6 嘉绒藏族民居木质构件损伤数据集构建流程

2.3 基于改进 YOLOv8 的损伤精准识别与精细化量化模型构建

针对丹巴嘉绒藏族民居木构件表面普遍覆盖精美装饰彩绘、且长期暴露于高原强紫外线环境下导致表面风化严重的现状，本研究旨在构建一个能够适应这种高复杂表观特征的“检测-分割-量化”一体化模型。在实际调研中发现，藏族民居独特的彩绘纹理多由规则线条与色块组成，其几何形态与木材表面的干缩裂缝高度相似，加之厨房油烟污渍及高原强光照产生的剧烈阴影干扰，导致传统算法极易产生混淆与误判。为此，本研究拟选用在工业界表现优异的 YOLOv8 算法作为基准框架，首先构建具有抗干扰能力的损伤检测模型。计划在主干网络中引入轻量级注意力机制模块，抑制背景中与检测目标相似的彩绘色彩与生活污渍噪声，引导模型将计算资源聚焦于裂缝、虫眼等具有特定特征的损伤区域，确保模型在面对风化泛白或阴影遮挡等复杂场景时仍保持稳定的特征提取能力。该改进目标检测模型的具体网络结构如图 7 所示。

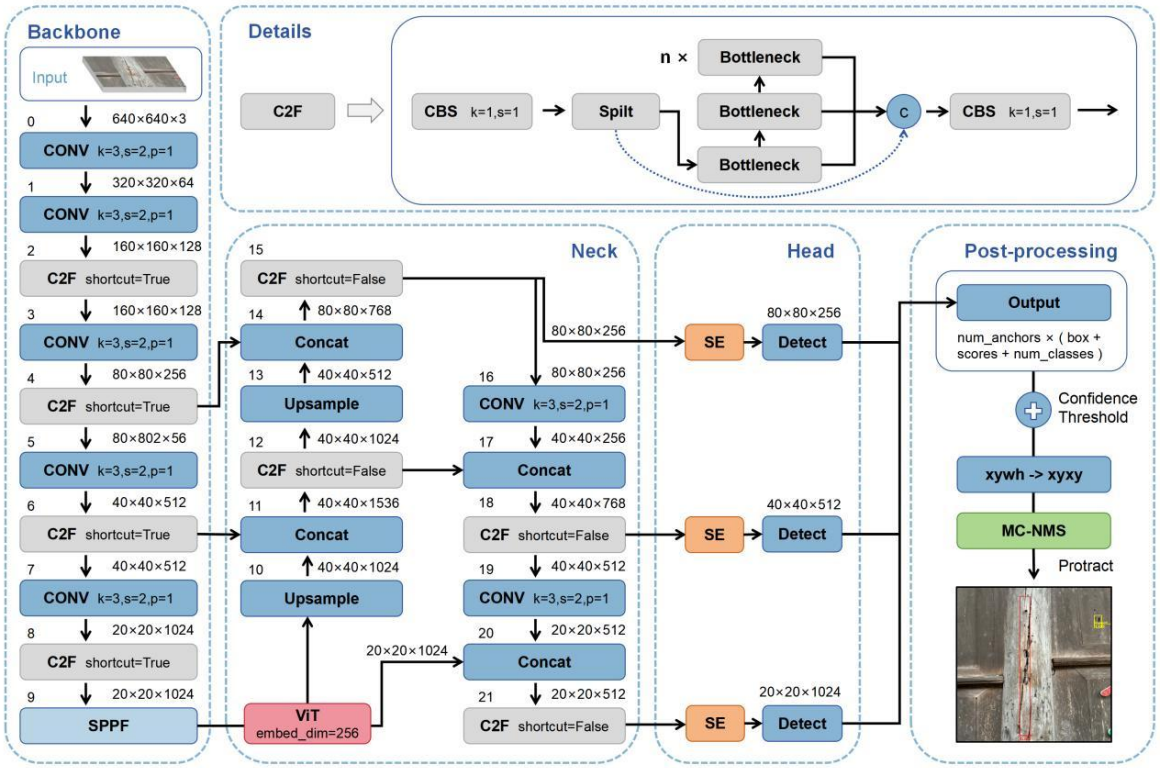


图 7 改进目标检测模型的结构

（作者自绘）

为进一步满足民居修缮的精细化评估需求，本研究将在实现损伤精准定位的基础上，构建基于 YOLOv8-Seg 的实例分割模型，实现检测与分割任务的并行处理。该模型利用主干网络提取的深层语义特征，一方面通过检测头输出病害的边界框实现定位；另一方面通过分割头生成原型掩膜及实例系数，经线性组合后生成与病害形状完全贴合的二值化掩码。这种像素级的分割架构能够有效解决不规则裂缝与虫蛀区域的边缘提取难题。基于分割掩码，研究将进一步建立损伤量化评估算法，通过统计掩码内的像素数量并结合比例尺，自动计算裂缝的长度、平均宽度以及腐朽区域的实际物理面积，进而生成损伤密度指标。这一过程将定性的视觉图像转化为定量的工程数据，为后续的受损等级判定与修缮决策提供直接的数据支撑。

2.4 损伤时空分布规律揭示与预防性保护策略构建

本研究的关键落脚点在于利用算法识别结果，揭示嘉绒藏族民居损伤发生的时空规律与内在机理。通过对识别出的损伤目标进行分类汇总，研究将定量分析不同类型损伤在建筑不同部位的分布占比，例如：统计裂缝是否更多地集中在承重的梁、柱构件上，

而虫蛀是否更倾向于分布在门窗等装饰性构件上。同时，研究将尝试把损伤分布数据与当地的微环境因素建立关联，分析迎风面与背风面、底层与顶层木构件在腐朽程度上的差异，探讨降雨量、日照强度等环境因子对木材老化的具体影响。通过数据挖掘式的分析，从原本零散的图像数据中提炼出具有规律性的结论，探究“什么构件最容易坏”以及“在什么环境下最容易坏”这两个核心问题。

基于上述的损伤识别与统计分析结果，提出具有针对性的预防性保护策略与修缮建议。研究将根据损伤的类型、程度以及其所处构件的重要性，建立一套分级评估体系。例如，对于识别出存在宽大裂缝的承重梁、柱，系统将判定为“结构安全风险”，并提出“更换木材”或“碳纤维加固”的建议；而对于仅存在表面虫蛀或轻微腐朽的门窗装饰，则判定为“外观审美风险”，提出“防虫熏蒸”或“表面防腐涂刷”的保养建议，从而建立一套“识别—量化—决策”的闭环反馈机制。

系统首先利用深度学习算法精准定位损伤并计算其几何参数（如裂缝长度、腐朽占比）；随后，依据构件的受力属性（承重/装饰）引入差异化权重因子；最后，对照《古建筑木结构维护与加固技术规范》及上述分级标准，自动生成从“日常保养”到“抢救性干预”的分级策略。依据深度学习模型输出的损伤识别结果（位置、类型）与量化参数（面积占比、裂缝宽高比），结合构件的结构重要性（承重/非承重），拟构建如下三级评估体系（见表 4），将算法数据映射为具体的工程干预指令，实现“分级确权、精准施策”。

表 4 分级干预标准表

评估等级	典型识别特征	涉及构件类型	风险定性	推荐预防性保护与修缮策略
I 级：轻微损伤（日常保养级）	裂缝：表面细微干缩裂纹(宽度<3mm)虫蛀：零星虫眼(密度<5 个/dm^2)腐朽：仅表层变色，无材质剥落	全类型构件(重点关注装饰构件)	外观审美风险结构处于健康状态，仅影响美观或存在潜在隐患。	非介入性保养：1.建档监测：记录损伤位置，纳入数字档案定期比对。2.表面防护：清洁积灰，涂刷桐油或透明防腐涂料。3.环境调控：改善通风条件，降低局部湿度。
II 级：中度损伤（一般修缮）	裂缝：纵向裂缝延伸(3mm≤宽度<10mm)虫蛀：局部密集虫眼，有木粉排出腐朽：腐朽面积占比 10%-30%，伴有轻微材质缺	非承重构件(门、窗、栏杆)次要承重构件(檐檩、挑枋)	功能退化风险装饰纹理受损，或构件局部力学性能下降，但未危及整体安全。	局部介入性修缮：1.填充修补：使用木屑腻子或环氧树脂对裂缝进行嵌补。2.生物防治：针对虫眼区域进行药物注射或整体熏蒸。3.剔补加固：剔除腐朽部位，采用传统工艺（镶补）恢复外观。

III 级：严重损伤（抢救干预）	损 裂缝：贯穿性裂缝或受力裂缝(宽度≥10mm)虫蛀：内部中空，敲击声沉闷腐朽：深度腐朽或面积占比>30%，出现明显的截面损失	关键承重构件(大木立柱、主梁、底层圈梁)	结构安全风险构件丧失承载能力，存在断裂或引发建筑局部坍塌的极高风险。	结构性抢救干预：1.现代材料加固：采用碳纤维布包裹或内嵌钢板加固。2.构件更换/墩接：对无法修复的梁柱进行落架大修，实施墩接或整体更换。3.临时支护：在修缮前立即架设临时支撑，防止倒塌。

通过这种方式，把算法识别结果转化为可执行的工程决策辅助信息，切实解决传统人工巡检中“看不全、判不准、记不住”的难题，将抽象的算法数据转化为了可直接指导工程实践的决策辅助信息，为丹巴嘉绒藏族民居的数字化建档与长效维护提供科学依据。

3. 研究创新点

构建首个嘉绒藏族民居木质构件损伤数据集 JTTD：针对现有公开数据集缺乏藏式建筑特征且标注粗糙的现状，本研究构建了首个嘉绒藏族民居木质构件损伤专用数据集——JTTD (Jiarong Tibetan Timber Damage Dataset)，为民族建筑保护领域的深度学习研究提供了高价值的数据来源，填补了该领域的数据空缺，这一工作不仅为深度学习模型提供了高价值的训练来源，更为后续分析损伤与建筑结构的关联性奠定了独有的数据基础。

构建面向复杂干扰背景的木质构件损伤特征增强与自适应识别算法：针对嘉绒藏族民居所处的强紫外线、光照剧烈变化以及室内常年柴火烟熏造成的与目标损伤高度相似的复杂背景，本研究构建了一种抗干扰能力强的算法模型。计划通过在 YOLOv8 基准模型中嵌入特定的注意力机制模块，解决在非结构化高噪环境下对微小损伤（如早期干缩裂缝、细微虫眼）的特征提取难题，显著提升了深度学习技术在特定垂直领域的应用深度。

（1）建立基于损伤分布统计的差异化修缮决策评估体系：本研究打破了传统研究止步于识别的局限，建立了从损伤识别到量化统计分析再到修缮决策的完整逻辑闭环。研究并未满足于仅仅框出损伤的位置，而是进一步提出了基于识别结果的量化统计方法，揭示了不同类型损伤在建筑承重结构与装饰部件上的分布规律，以及其与局部微环境（如迎风面、潮湿面）的关联机制。基于这一统计规律，本研究提出了一套差异化的修缮决策评估体系：即根据损伤位置、类型特征和结构重要性评估不同风险等级，自动

推荐不同层级的干预措施，将深度学习技术真正转化为指导现场施工与预防性保护的科学依据，体现了显著的工程应用创新。

4. 拟解决的关键问题

（1）强干扰背景下的木质构件损伤特征精准提取：基于 YOLOv8 构建面向复杂背景的木质构件损伤检测的深度学习目标检测框架，作为损伤识别的基础模型；针对彩绘纹理与环境噪声干扰，在模型主干网络中嵌入注意力机制模块，调整网络层数与超参数，使其能够准确聚焦损伤特征并抑制背景噪声；利用构建好的 JTTD 数据集对模型进行迭代训练与参数优化，通过损失函数曲线监控训练过程，确保模型快速收敛；用训练好的最优模型对测试集图像进行推理测试，实现自动提取裂缝、虫眼等损伤高精度的精准提取与定位。

（2）建立基于损伤点位分布统计的量化评估与修缮决策映射机制

利用算法识别结果，量化分析不同类型损伤在承重结构与装饰构件上的分布占比规律，并结合当地微环境解释其成因；进而，根据这一统计结果建立分级评估模型，将抽象的损伤数据转化为具体的工程干预建议，实现人工智能技术在乡土建筑预防性保护中的工程化落地。

三、研究方案、进度安排，可能遇到的困难和问题及解决方案

1 研究方案与方法

1.1 研究方案

通过对各部分内容的分析，梳理出了嘉绒藏族民居木质构件损伤识别研究的技术路线图，如图 8 所示。

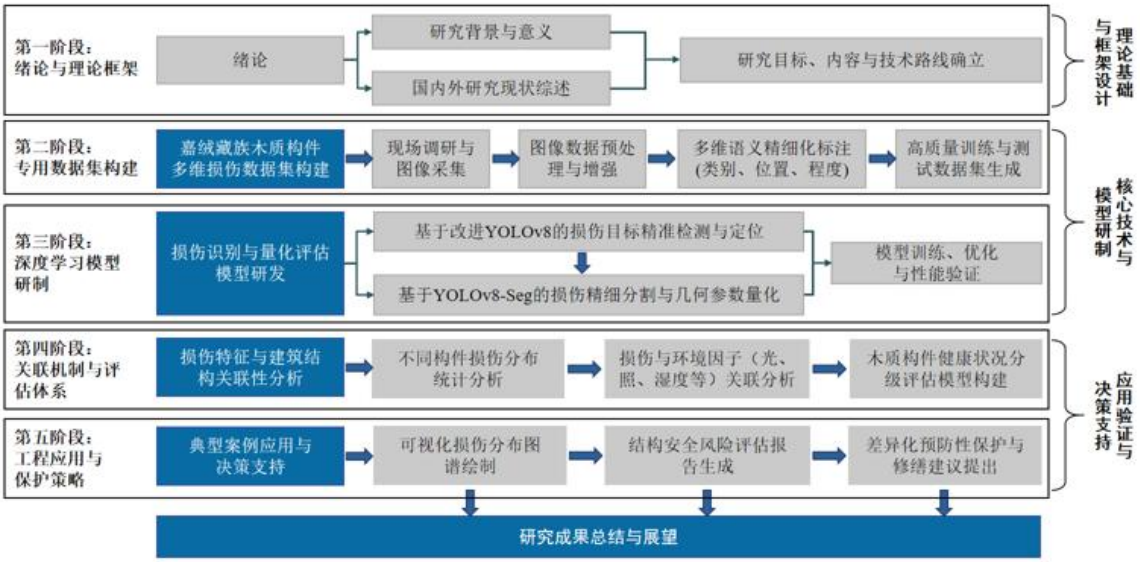


图 8 技术路线图

1.2 研究方法

本研究利用深度学习计算机视觉技术来解决嘉绒藏族民居木质构件损伤识别的实际问题，其过程涉及多领域多学科。为找到解决问题的实用方法，本研究拟采用多种方法进行研究，具体包括文献研究法、实例分析法、跨学科技术研究法、计算机图像识别法实验法。

（1）文献研究法

为确保对研究问题进行全面、准确的理解和掌握，本研究在仔细研读已有的相关文献和研究，了解领域内已有的知识、理论和方法的基础上，分析现有的研究成果，梳理现有方法存在的问题和面临的挑战，提供对特定领域的全面理解和背景知识，帮助明确研究问题、选择合适方法、避免重复研究，为研究内容提供指导，确保研究的科学性和可靠性。

（2）实例分析法

基于以上所提出的研究内容和研究方法，对提出的检测方法进行实例分析。选取丹巴县莫洛村等典型嘉绒藏族民居开展实地调研。采用无人机航拍、高清数码摄影、激光测距仪等设备，系统采集木质构件损伤情况图像数据。同步开展入户访谈与结构化问卷调查，记录建筑年代、修缮历史、使用状况及居民认知，为模型训练与验证提供真实场

景支撑。

（3）跨学科技术研究法

本研究拟结合计算机视觉、图像处理、软件开发等学科的知识和技术成果，对巴嘉绒藏族民居木质构件损伤检测进行综合研究。

（4）计算机图像识别法

基于采集的图像数据，构建适用于嘉绒民居的智能识别与损伤分析流程：首先，采用改进的 YOLOv8 目标检测模型，结合语义分割技术（如 U-Net 或 Mask R-CNN），实现对虫蛀、裂缝、腐朽、霉变、木结等典型构件的高精度识别与轮廓提取；进而，针对木构件表面损伤，引入多尺度特征融合与注意力机制，提升对细小裂缝、局部腐朽等弱信号的敏感性；最终，结合三维裂缝量化算法（如基于像素—物理尺度映射的宽度估算模型），对损伤区域进行像素级测量，实现损伤类型分类、面积计算与严重等级判定的自动化输出。

（5）对比实验与消融分析法

为验证本研究提出算法的先进性，设计严格的横向对比实验和消融实验，横向对比指将 MC-YOLOv8 与主流算法（如原始 YOLOv8、Faster R-CNN、SSD）在同一数据集上进行对比，评估 mAP（平均精度均值）、Recall（召回率）等指标；消融实验则是逐步移除改进模块，观察模型性能的变化，以定量分析每个改进点对最终结果的贡献度，证明算法设计的合理性。

2 进度安排

本研究进度及其安排如下所示：

序号	研究内容	2025年	2026年											2027年			
		12月	1月	2月	3月	4月	5月	6月	7月	8月	9月	10月	11月	12月	1月	2月	3月	4月
1	文献和框架完善	■																
2	模型构建与调试		■	■														
3	实地调研和数据采集				■													
4	数据分类和预处理					■	■											
5	损伤检测和量化分析评估							■	■	■								
6	村落建筑木质构件实例分析										■	■						
7	撰写论文												■	■	■			
8	修改论文并定稿															■	■	■

3 可能遇到的问题及解决方案

3.1 可能遇到的困难

(1)数据采集难：特殊地理与建筑环境导致图像采集质量不稳定，丹巴藏寨多位于高山峡谷，碉楼与民居往往高达十余米，导致高处的斗拱、屋檐等关键构件难以近距离拍摄。加之高原光照太强，照片容易出现一半过亮、一半昏暗的情况，损伤特征不清晰。

(2)网络模型构建较难：专用网络架构设计与参数调优困难，针对嘉绒藏族民居独特的复杂纹理特征，现有的通用网络模型难以直接适用，必须构建针对性的专用神经网络。这需要在算法结构中引入新的模块，导致网络结构设计复杂，后续的代码复现、超参数调试及模型优化过程极具挑战性。

(3)训练难：严重损伤的样本太少，模型数据量不足，在实际修缮中，真正断裂或严重腐朽的构件是少数，大部分构件只是轻微受损。这就导致我们采集到的数据里，“坏样本”太少，“好样本”太多。数据比例不平衡，会让模型学不到严重损伤的特征，难以应对复杂情况。

(4)量化难：用手机、相机等设备拍照获取的图像数据，难以测量实际尺寸，照片里的一条裂缝，离得近拍看着就大，离得远拍看着就小。在不知道具体拍摄距离的情况下，没法直接算出裂缝到底有几厘米长，难以直接套用国家标准进行等级判定。

3.2 拟采取的解决方案

(1)设备辅助与图像预处理解决采集难题：针对高处构件，利用无人机配合长焦镜头进行贴近拍摄，解决“拍不到”的问题。针对光照不均匀，使用图像去雾与亮度平衡算法对照片进行预处理，把过亮的地方压暗，把过黑的地方提亮，还原阴影里的纹理细节，确保图像清晰可用。针对严重损伤样本少的问题，采用数据增强策略，通过旋转、拼接、模拟光照等方式，人为增加样本的数量。同时，利用迁移学习技术，先让模型学习公开的大规模木材缺陷数据，掌握通用的识别能力，再用已采集的丹巴数据进行微调。

(2)抗干扰特征增强解决彩绘误判难题：调整算法的注意力机制，训练模型学会忽略颜色、看重形状。通过算法优化，降低模型对彩绘颜色的敏感度，强制模型去关注裂缝边缘特有的破碎感和深度感，从而把原本混在一起的彩绘线条和真实裂缝区分开来。

(3)针对建筑特征量化方法较少、神经网络构建难问题：可以大量阅读建筑特征提取和量化分析的相关文献，查找已有的研究和开源工具，参考其方法结合自身研究特点设计适合本研究的方法；学习机器学习和编程语言的视频课程，提升对这些技术和计算机

语言的理解和应用能力，为构建和调试神经网络打下坚实基础，可以在 GitHub 上寻找与研究相关的开源项目和示例代码，还可以利用预训练的神经网络模型如 VGG、ResNet 等，由于这些模型已经在大规模数据上进行了训练，对其进行微调从而用作本研究的基础模型，因此来降低构建和训练模型的难度。

(4)相对占比评估解决无法测量难题:利用算法计算损伤区域在整个构件表面占了多大比例，或者分析裂缝形状及其形态。通过相对指标，建立一套专门的严重度分级标准如轻微、中度、严重。

四、与本题目有关的研究工作积累和已取得的研究工作成绩

4.1 知识体系构建

本人在选题前期对研究区域——四川省甘孜州丹巴县进行了详尽的背景调研与多次实地考察，构建了“历史—构造—环境”的感性认知。通过深入研读嘉绒藏族建筑历史文献并结合实地调研，本人深刻把握了“千碉之国”的文化内涵，重点掌握了丹巴典型民居及碉楼特有的构造逻辑，厘清了梁、柱、枋、楼板等核心木质构件的连接形式与作用机制。同时，针对丹巴县高山峡谷地貌及高海拔气候特征，明确了在该特定环境下木材主要面临的物理风化与生物侵害机理，为算法设计提供了针对性提取几何特征与纹理特征的明确导向。此外，基于对当地修缮历史的调研，本人已具备区分历史人工痕迹（如室内长期烟熏黑化、传统加工痕迹）与结构损伤的能力。

4.2 嘉绒藏族木结构损伤基准数据集的构建

针对现有公开数据集缺乏藏族乡土建筑特征的痛点，本人利用实地采集的高清影像数据，初步构建了“嘉绒藏族木结构损伤数据集 JTTD（Jiarong Tibetan Timber Damage Dataset）”。该数据集涵盖了不同光照条件、不同拍摄角度以及不同污损程度的木质构件图像，确保了数据的多样性与现实场景的还原度。在标注策略上，本研究不仅对图像中的裂缝、虫眼、腐朽、节子等目标进行了精细化标注，还创造性地引入了建筑学语义逻辑，初步尝试了结合构件类型的关联标注（如图 9 所示）。这种构建方式确保了数据集不仅包含病害的表观特征，还隐含了病害的空间分布信息，为后续分析损伤与建筑结构的关联性储备了高质量的数据资产，解决了传统数据集语义维度单一的问题。

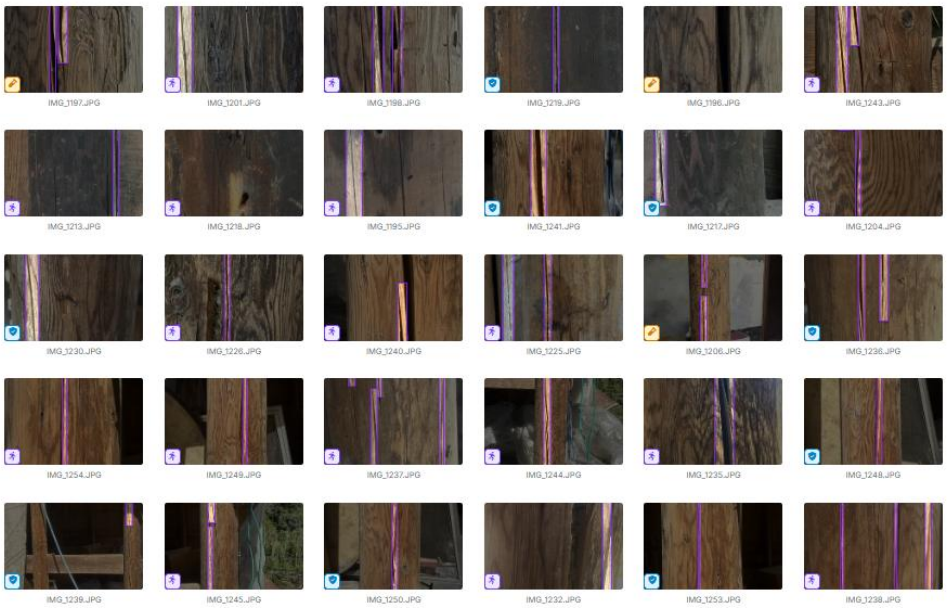


图 9 嘉绒藏族木结构损伤数据集

4.3 软硬件实验环境保障

本研究属于计算密集型任务，对实验设备的算力有较高要求，目前已具备了完善的软硬件实验环境。在数据采集方面，课题组拥有完备的影像采集设备，包括用于捕捉微观纹理的高分辨率全画幅单反相机（Sony/Canon 系列），以及用于高空及悬挑构件贴近摄影测量的 DJI Mavic 3 行业级无人机，能够满足从宏观场景到微观细节的全方位数据采集需求。在计算机硬件方面，本人拥有一台配置高性能 NVIDIA 显卡并支持 CUDA 并行计算的深度学习工作站，显存与内存容量充足，能够满足 YOLOv8 等深度神经网络模型在大规模数据集下的训练与推理需求；同时配备了大容量移动存储设备，确保了海量高分辨率图像数据（JTTD 数据集）的安全存储与备份。在软件方面，已成功搭建了基于 Windows 系统的完整深度学习开发环境，熟练配置了 Anaconda 虚拟环境、PyTorch 深度学习框架以及对应的 CUDA/cuDNN 加速库，并解决了环境依赖冲突问题。

4.4 研究已具有的前期基础

在数据准备层面，本人已完成了对原始调研图像的深度清洗与筛选，剔除了模糊、过曝及重复的无效样本，初步构建了嘉绒藏族民居木质构件损伤数据集（JTTD）的基础架构。目前，已利用 LabelImg 等专业标注软件制定了统一的标注规范，完成了数百张典型样本的精细化标注工作，确立了包含裂缝、虫眼、腐朽等核心病害的标签体系。利用这部分小规模数据集进行了 YOLOv8 模型的预训练实验，成功打通了从“数据加载—模型训练—结果推理”的全技术流程。初步的实验结果显示，模型已具备基础的识别

能力，能够收敛并检测出明显的损伤特征（见图 10）。这一阶段性的工作不仅验证了本课题技术路线在逻辑上的连通性，也通过实测数据暴露了复杂背景下的识别难点，为后续大规模数据集的扩充与算法的针对性改进提供了明确的方向和宝贵的调试经验。



图 10 初步检测效果

4.5 依托项目与经费支持

在资源支持方面，学校及实验室提供了丰富的学术数据库权限（如 CNKI、Web of Science、IEEE Xplore 等），为查阅国内外前沿文献提供了便利；导师及课题组师兄师姐在计算机视觉与建筑遗产保护领域拥有丰富的经验，能够为本研究在理论构建与技术路线上提供持续的专业指导。在经费保障方面，依托相关科研项目，拥有充足的科研经费支持。经费额度能够全额覆盖本研究在实地调研中产生的差旅费、数据采集设备（如无人机配件、测距仪）购置费，以及后续的论文发表版面费与专利申请费用，确保课题能够按照既定计划顺利、高质量地推进。

五、参考文献

[1] 王晨.全国人民代表大会常务委员会执法检查组关于检查《中华人民共和国乡村振兴促进法》实施情况的报告——2022 年 10 月 28 日在第十三届全国人民代表大会常务委员会第三十七次会议上[J].中华人民共和国全国人民代表大会常务委员会公报,2022,(06):970-980.

[2] 杨春华,刘俊杰,王慧敏.进一步深化农村改革扎实推进乡村全面振兴——学习贯彻 2025 年中央一号文件精神笔谈[J].农林经济管理学报,2025,24(02):157-164.

[3] 中华人民共和国中央人民政府. 中共中央、国务院印发《农村人居环境整治提升五年行动方案（2021—2025 年）》[EB/OL]. https://www.gov.cn/zhengce/2021-12/05/content_5655984.htm [J].

[4] 中华人民共和国中央人民政府.国务院印发《中共中央国务院关于全面推进乡村振兴加快农业农村现代化的意见》[EB/OL]. https://www.gov.cn/zhengce/2021-02/21/content_5588098.htm [J].

[5] 中华人民共和国中央人民政府. 中共中央、国务院印发《关于推进实施国家文化数字化战略的意见》[EB/OL]. https://www.gov.cn/zhengce/2022-05/23/content_5691982.htm [J].

[6] 刘韫.旅游背景下少数民族村落的传统民居保护研究——以嘉绒藏族民居为例[J].西南民族大学学报(人文社会科学版),2014,35(02):155-158.

[7] 胡冬雯,张菁.家屋的拓扑学：嘉绒藏族民居建筑的有机更新[J].建筑学报,2025,(04):113-118.DOI:10.19819/j.cnki.ISSN0529-1399.202504017.

[8] 孙娜,罗德胤,范秉乾.在神山与碉楼之间——四川省丹巴县中路乡传统村落集中连片示范规划设计[J].城市设计,2024,(02):12-27.

[9] 袁霄, 陈勇平, 郭文静. 古建筑木结构多发残损的特征及防控分析[J]. 木材科学与技术, 2023, 35(5): 54-59.

[10] 钟明全. 疲劳加载对部分预应力混凝土梁钢筋应力、 裂缝宽度及静力强度的影响[J]. 西南交通大学学报, 1995(03): 283-290.

[11] 聂建国, 沈聚敏. 钢筋混凝土梁长期斜裂缝宽度的试验研究[J]. 建筑结构学报,1995(03):1-9.

[12] 张海明. 土木工程结构中远距离非接触式表面缺陷及裂缝检测系统研究[D].北京: 中冶集团建筑研究总院, 2013.

[13] 严盛龙, 徐飞鸿. 基于亚像素算法的混凝土结构裂缝测量[J]. 交通科学与工程,2017, 33(04):31-36.

[14] 李伟, 岳德鹏. 基于机器视觉的立木树干边缘检测及边缘直线提取[J]. 林业资源管理, 2018(05):1 13-122.

[15] 周颖, 刘彤. 基于计算机视觉的混凝土裂缝识别[J]. 同济大学学报(自然科学版), 2019, 47(09): 1277-1285.

[16] 房铭坤, 付国. 基于数字图像处理的混凝土裂缝宽度检测方法研究[J]. 建筑结构, 2019, 49(S2): 630-634.

[17] 韩豫, 孙昊, 李雷,等. 基于无人机的建筑外墙裂缝快速检查系统设计与实现[J]. 土木工程与管理学报, 2019, 36(03): 60-65.

[18] 车紫进. 基于机器视觉的混凝土裂缝识别与量化方法研究[D]. 哈尔滨: 哈尔滨工业大学, 2020.

[19] 杨才千, 李帅, 王博昆,等. 基于动态阈值的混凝土裂缝高抗噪提取及识别方法[J]. 东南大学学报(自然科学版), 2021,51(06): 967-972.

[20] Hatır M E, İnce İ, Korkanç M. Intelligent detection of deterioration in cultural stone heritage[J]. Journal of Building Engineering, 2021, 44: 102690.

[21] Dais D, Bal I E, Smyrou E, et al. Automatic crack classification and segmentation on masonry surfaces using convolutional neural networks and transfer learning[J]. Automation in Construction, 2021, 125: 103606.

[22] 王睿, 漆泰岳. 基于机器视觉检测的裂缝特征研究[J]. 土木工程学报, 2016,49(07): 123-128.

[23] 王丽苹, 高瑞贞, 张京军,等. 基于卷积神经网络的混凝土路面裂缝检测[J].计算机科学, 2019, 46(S2): 584-589.

[24] 褚鸿鹄. 基于可变形卷积神经网络 的混凝土裂缝 图像检测[D]. 哈尔滨: 哈尔滨工业大学, 2020.

[25] 骆剑彬, 姜绍飞, 沈圣,等. 基于声呐成像的水下桩墩表观病害深度学习与智能检测[J]. 土木工程学报, 2021, 54(07): 90-100.

[26] DaisD, BalIE, SmyrouE, et al. Automatic crack classification and segmentation on masonry surfaces using convolutional neural networks and transfer learning[J]. Automation in Construction, 2021, 125.

[27] 温作林. 基于深度学习的混凝土裂缝识别[D]. 杭州: 浙江大学, 2019.

[28] 张兴成. 基于大数据分析的桥梁裂缝图像识别技术研究[D]. 南京: 东南大学,2019.

[29] ParkSE, EemSH, JeonH. Concrete crack detection and quantification using deep learning and structured light[J]. Construction and Building Materials, 2020, 252:119096.

[30] 翁飘. 复杂环境下路面裂缝分割算法研究[D]. 郑州: 郑州大学,2019.

[31] 沈俊凯. 基于计算机视觉的混凝土裂缝检测算法研究[D]. 哈尔滨: 中国地震局工程力学研究所, 2019.

[32] 陈波, 张华, 汪双,等. 基于全卷积神经网络的坝面裂纹检测方法研究[J].水力发电学报, 2020, 39(07): 52-60.

[33] 朱苏雅, 杜建超, 李云松,等. 采用 U-Net 卷积网络的桥梁裂缝检测方法[J].西安电子科技大学学报, 2019, 46(04): 35-42.

[34] 任秋兵, 李明超, 沈扬,等. 水工混凝土裂缝像素级形态分割与特征量化方法[J]. 水力发电学报, 2021, 40(02): 234-246

[35] 徐国整, 廖晨聪, 陈锦剑,等.基于 HU-ResN et 的混凝土表观裂缝信息提取[J].计算机工程, 2020, 46(11): 279-285.

[36] PanG, ZhengYX, GuoS, et al. Automatic sewer pipe defect semantic segmentation based on improvedU-Net[J]. Automation in Construction, 2020,1 19.

[37] KimB, YuvarajN, ParkHW, et al. Investigation of steel frame damage based on computer vision and deep learning[J]. Automation in Construction, 2021, 132.

[38] 代洋洋, 王宽全. UU-Net: 基于 U-Net 的 U 形多路径网络的视网膜血管分割[J].哈尔滨工程大学学报, 2020, 41(05): 718-723.

[39] Ma J, Yan W, Liu G, et al. Complex texture contour feature extraction of cracks in timber structures of ancient architecture based on YOLO algorithm[J]. Advances in Civil Engineering, 2022, 2022(1): 7879302.

[40] Qiu H, Zhang J, Zhuo L, et al. Research on intelligent monitoring technology for roof damage of traditional Chinese residential buildings based on improved YOLOv8: taking ancient villages in southern Fujian as an example[J]. Heritage Science, 2024, 12(1): 231.

[41] 戴俭, 常丽红, 钱威,等. 古建筑木构件残损特征及其内部空洞的应力波无损检测[J]. 北京工业大学学报, 2016, 42(02): 236-244.

[42] 张晓芳. 阻力仪在古建筑木构件勘查中的应用研究[D]. 北京: 北京林业大学,2007.

[43] 黄荣凤, 王晓欢, 李华,等. 古建筑木材内部腐朽状况阻力仪检测结果的定量分析[J]. 北京林业大学学报, 2007(06): 167-171.

[44] 李鑫. 古建筑木构件材质性能与残损检测关键技术研究[D]. 北京: 北京工业大学, 2015.

[45] 黄英来, 刘亚檀, 任洪娥. 基于全卷积神经网络的林木图像分割[J]. 计算机工程与应用, 2019, 55(04): 219-224.

[46] 王念念. 深度学习在古建筑表面损伤检测中的应用研究[D]. 大连: 大连理工大学, 2019.

[47] 马健, 阎卫东, 刘国奇. 基于 YOLO v5 的古建筑木结构裂缝检测方法[J]. 沈阳建筑大学学报(自然科学版), 2021, 37(05): 927-934.

[48] 杨娜, 张翀, 李天昊. 基于无人机与计算机视觉的中国古建筑木结构裂缝监测系统设计[J]. 工程力学, 2021, 38(03): 27-39.

[49] 杨娜, 汪德佳, 李天昊,等. 基于计算机视觉方法的古建筑变形监测[J/OL].建筑结构学报, 2022-02-02:1-10.

[50] Nasir V, Ayanleye S, Kazemirad S, et al. Acoustic emission monitoring of wood materials and timber structures: A critical review[J]. Construction and Building Materials, 2022, 350: 128877.

[51] Zhao K, Ge Z, Huo L, et al. Application progress and prospect of defect detection technology for timber structure members[J]. Russian Journal of Nondestructive Testing, 2024, 60(4): 455-469.

[52] Zhang L, Xie Q, Wang H, et al. Deep-Learning-Based Crack Identification and Quantification for Wooden Components in Ancient Chinese Timber Structures[J]. Structural Control and Health Monitoring, 2024, 2024(1): 9999255.

[53] Hatır M E, İnce İ, Korkanç M. Intelligent detection of deterioration in cultural stone heritage[J]. Journal of Building Engineering, 2021, 44: 102690.

[54] Qian X, Yang N. Deep learning for anomaly detection in traditional Tibetan timber structures: A VAE-based model with multi-head attention and LSTM encoding and state-based thresholding[C]//Structures. Elsevier, 2025, 77: 109092.

[55] Hussain M. YOLO-v1 to YOLO-v8, the rise of YOLO and its complementary nature toward digital manufacturing and industrial defect detection[J]. Machines, 2023, 11(7): 677.

[56] Migneco P. Traffic sign recognition algorithm: a deep comparison between Yolov5 and SSD Mobilenet[D]. Politecnico di Torino, 2024.

[57] Tang J, Liu S, Zhao D, et al. PCB-YOLO: An improved detection algorithm of PCB surface defects based on YOLOv5[J]. Sustainability, 2023, 15(7): 5963.

[58] Zhang Z. Drone-YOLO: An efficient neural network method for target detection in drone images[J]. Drones, 2023, 7(8): 526.

[59] Hao X, Liu L, Yang R, et al. A review of data augmentation methods of remote sensing image target recognition[J]. Remote Sensing, 2023, 15(3): 827.

附录

YOLOv8 目标检测模型训练代码

```
from __future__ import annotations
import math
import random
from copy import copy
from typing import Any
import numpy as np
import torch
import torch.nn as nn
from ultralytics.data import build_dataloader, build_yolo_dataset
from ultralytics.engine.trainer import BaseTrainer
from ultralytics.models import yolo
from ultralytics.nn.tasks import DetectionModel
from ultralytics.utils import DEFAULT_CFG, LOGGER, RANK
from ultralytics.utils.patches import override_configs
from ultralytics.utils.plotting import plot_images, plot_labels
from ultralytics.utils.torch_utils import torch_distributed_zero_first, unwrap_model


class DetectionTrainer(BaseTrainer):
    """
    A class extending the BaseTrainer class for training based on a detection model.

    This trainer specializes in object detection tasks, handling the specific requirements for training YOLO models for
    object detection including dataset building, data loading, preprocessing, and model configuration.
```

```
    Attributes:
        model (DetectionModel): The YOLO detection model being trained.
        data (dict): Dictionary containing dataset information including class names and number of classes.
        loss_names (tuple): Names of the loss components used in training (box_loss, cls_loss, dfl_loss).
    """

    def __init__(self, cfg=DEFAULT_CFG, overrides: dict[str, Any] | None = None, _callbacks=None):
        """
        Initialize a DetectionTrainer object for training YOLO object detection model training.

        Args:
            cfg (dict, optional): Default configuration dictionary containing training parameters.
            overrides (dict, optional): Dictionary of parameter overrides for the default configuration.
            _callbacks (list, optional): List of callback functions to be executed during training.
        """
        super().__init__(cfg, overrides, _callbacks)

    def build_dataset(self, img_path: str, mode: str = "train", batch: int | None = None):
        """
        Build YOLO Dataset for training or validation.

        Args:
            img_path (str): Path to the folder containing images.
            mode (str): 'train' mode or 'val' mode, users are able to customize different augmentations for each mode.
            batch (int, optional): Size of batches, this is for 'rect' mode.

        Returns:
            (Dataset): YOLO dataset object configured for the specified mode.
        """
        gs = max(int(unwrap_model(self.model).stride.max() if self.model else 0), 32)
        return build_yolo_dataset(self.args, img_path, batch, self.data, mode=mode, rect=mode == "val", stride=gs)

    def get_dataloader(self, dataset_path: str, batch_size: int = 16, rank: int = 0, mode: str = "train"):
        """
        Construct and return dataloader for the specified mode.

        Args:
            dataset_path (str): Path to the dataset.
            batch_size (int): Number of images per batch.
            rank (int): Process rank for distributed training.
```

```
            mode (str): 'train' for training dataloader, 'val' for validation dataloader.

        Returns:
            (DataLoader): PyTorch dataloader object.
        """
        assert mode in {"train", "val"}, f"Mode must be 'train' or 'val', not {mode}."
        with torch_distributed_zero_first(rank):  # init dataset *.cache only once if DDP
            dataset = self.build_dataset(dataset_path, mode, batch_size)
        shuffle = mode == "train"
        if getattr(dataset, "rect", False) and shuffle:
            LOGGER.warning("'rect=True' is incompatible with DataLoader shuffle, setting shuffle=False")
            shuffle = False
        return build_dataloader(
            dataset,
            batch=batch_size,
            workers=self.args.workers if mode == "train" else self.args.workers * 2,
            shuffle=shuffle,
            rank=rank,
            drop_last=self.args.compile and mode == "train",
        )

    def preprocess_batch(self, batch: dict) -> dict:
        """
        Preprocess a batch of images by scaling and converting to float.

        Args:
            batch (dict): Dictionary containing batch data with 'img' tensor.

        Returns:
            (dict): Preprocessed batch with normalized images.
        """
        for k, v in batch.items():
            if isinstance(v, torch.Tensor):
                batch[k] = v.to(self.device, non_blocking=self.device.type == "cuda")
        batch["img"] = batch["img"].float() / 255
        if self.args.multi_scale:
            imgs = batch["img"]
            sz = (
                random.randrange(int(self.args.imgsz * 0.5), int(self.args.imgsz * 1.5 + self.stride))
                // self.stride
                * self.stride
            )  # size
            sf = sz / max(imgs.shape[2:])  # scale factor
```

```
            if sf != 1:
                ns = [
                    math.ceil(x * sf / self.stride) * self.stride for x in imgs.shape[2:]
                ]  # new shape (stretched to gs-multiple)
                imgs = nn.functional.interpolate(imgs, size=ns, mode="bilinear", align_corners=False)
            batch["img"] = imgs
        return batch

    def set_model_attributes(self):
        """Set model attributes based on dataset information."""
        self.model.nc = self.data["nc"]  # attach number of classes to model
        self.model.names = self.data["names"]  # attach class names to model
        self.model.args = self.args  # attach hyperparameters to model

    def get_model(self, cfg: str | None = None, weights: str | None = None, verbose: bool = True):
        """
        Return a YOLO detection model.

        Args:
            cfg (str, optional): Path to model configuration file.
            weights (str, optional): Path to model weights.
            verbose (bool): Whether to display model information.

        Returns:
            (DetectionModel): YOLO detection model.
        """
        model = DetectionModel(cfg, nc=self.data["nc"], ch=self.data["channels"], verbose=verbose and
RANK == -1)
        if weights:
            model.load(weights)
        return model

    def get_validator(self):
        """Return a DetectionValidator for YOLO model validation."""
        self.loss_names = "box_loss", "cls_loss", "dfl_loss"
        return yolo.detect.DetectionValidator(
            self.test_loader, save_dir=self.save_dir, args=copy(self.args), _callbacks=self.callbacks
        )

    def label_loss_items(self, loss_items: list[float] | None = None, prefix: str = "train"):
        """
        Return a loss dict with labeled training loss items tensor.
        """
        keys = [f"{prefix}/{x}" for x in self.loss_names]
```

```
        if loss_items is not None:
            loss_items = [round(float(x), 5) for x in loss_items]  # convert tensors to 5 decimal place floats
            return dict(zip(keys, loss_items))
        else:
            return keys

    def progress_string(self):
        """Return a formatted string of training progress with epoch, GPU memory, loss, instances and size."""
        return ("\n" + "%11s" * (4 + len(self.loss_names))) % (
            "Epoch",
            "GPU_mem",
            *self.loss_names,
            "Instances",
            "Size",
        )

    def plot_training_samples(self, batch: dict[str, Any], ni: int) -> None:
        """Plot training samples with their annotations."""
        plot_images(
            labels=batch,
            paths=batch["im_file"],
            fname=self.save_dir / f"train_batch{ni}.jpg",
            on_plot=self.on_plot,
        )

    def plot_training_labels(self):
        """Create a labeled training plot of the YOLO model."""
        boxes = np.concatenate([lb["bboxes"] for lb in self.train_loader.dataset.labels], 0)
        cls = np.concatenate([lb["cls"] for lb in self.train_loader.dataset.labels], 0)
        plot_labels(boxes, cls.squeeze(), names=self.data["names"], save_dir=self.save_dir, on_plot=self.on_plot)

    def auto_batch(self):
        """Get optimal batch size by calculating memory occupation of model."""
        with override_configs(self.args, overrides={"cache": False}) as self.args:
            train_dataset = self.build_dataset(self.data["train"], mode="train", batch=16)
        max_num_obj = max(len(label["cls"]) for label in train_dataset.labels) * 4  # 4 for mosaic augmentation
        del train_dataset  # free memory
        return super().auto_batch(max_num_obj)
```